

Universität Leipzig
Medizinische Fakultät
Institut für Medizinische Informatik, Statistik und Epidemiologie

OPTIMIERUNG VON FRAMEBASIERTER
SEGMENTIERUNG VON
ENDOSKOPIEVIDEOS DURCH
MULTILABELKLASSIFIKATION. VERGLEICH
VON MARKOV MODELS UND CONDITIONAL
RANDOM FIELDS.

MASTERARBEIT

zur Erlangung des akademischen Grades

Master of Science
(M. Sc.)

vorgelegt von

Max Hild
Studiengang Medizininformatik

Leipzig, den 03. Februar 2026

AUTOR:

Max Hild

Geboren am 19.09.1999 in Stuttgart, Deutschland

TITEL:

Optimierung von framebasierter Segmentierung von Endoskopievideos durch Multilabelklassifikation. Vergleich von Markov Models und Conditional Random Fields.

INSTITUT:

Institut für Medizinische Informatik, Statistik und Epidemiologie
Medizinische Fakultät Universität Leipzig

REFERENT:

Prof. Dr. Markus Scholz

BETREUER:

Dr. Thomas J. Lux

ZUSAMMENFASSUNG

Diese Arbeit untersucht, inwieweit die Nachbearbeitung framebasierter Segmentierungen von Endoskopievideos durch probabilistische Sequenzmodelle verbessert werden kann. Ziel ist eine robuste Vorselektion nicht relevanter Bildbereiche, um rechenintensive Deep-Learning-Modelle zu entlasten und die Analysepipeline zu stabilisieren. Im Fokus stehen die Klassen „outside“ und „low_quality“, die für Anonymisierung und Qualitätskontrolle entscheidend sind.

Methodisch werden ein HMM und ein Conditional Random Field auf denselben regelbasierten Feature-Satz angewandt. Die Merkmale umfassen Farbstatistiken, Bewegungsinformationen und Texturgrößen, die vorab statistisch kalibriert und zu deterministischen Emissionsregeln verdichtet werden. Zur Erhöhung der Robustheit wird der ursprüngliche Labelraum auf eine reduzierte Menge semantischer Klassen abgebildet.

Die Ergebnisse zeigen, dass das Conditional Random Field insgesamt konsistenter als das HMM arbeitet und in der Gesamtleistung höhere Werte erreicht. Beide Modelle sind besonders stark in der Erkennung von „outside“ und „low_quality“, während die Erkennung pathologischer Befunde wie Polypen mit keiner der beiden Methodiken möglich ist. Die Laufzeitanalyse bestätigt zudem eine Echtzeitfähigkeit im Millisekundenbereich pro Frame.

Damit liefert die Arbeit einen praktikablen Filter für die Endoskopie-segmentierung, der Datenströme zuverlässig bereinigen kann und die Grundlage für eine nachgelagerte, präzisere Befunddetektion schafft.

DANKSAGUNG

Ich danke Dr. Thomas Lux für die Anregungen sowie die fachliche und organisatorische Unterstützung während der gesamten Dauer dieser Arbeit. Ebenso danke ich Prof. Dr. Markus Scholz für die Übernahme des Gutachtens sowie für die Vermittlung der Methodik der Modellkonzeption. Ich danke weiterhin meinem Vater und meiner Oma dafür, dass Sie meine mathematischen Bestrebungen nicht aufgegeben haben und mich unterstützt haben, die Fähigkeiten zu erlangen die mir dazu verholfen haben diese Arbeit zu verfassen. Ich danke weiterhin meinem Bruder und meiner Schwester für all die kreativen Anregungen. Ich danke meiner Mutter für die mentale und beratende Unterstützung. Zuletzt danke ich meiner Freundin für ihr Verständnis und ihre umfassende Unterstützung während der Anfertigung dieser Arbeit.

INHALTSVERZEICHNIS

ZUSAMMENFASSUNG	iii
1 EINLEITUNG	1
1.1 Gegenstand der Forschung	1
1.1.1 Endoskopie als diagnostisches Werkzeug und zur Vorsorge	1
1.1.2 KI-gestützte Segmentierung in der Endoskopie	2
1.1.3 Herausforderungen bei der KI basierten Segmentierung von Endoskopievideos	3
1.2 Problemstellung	3
1.3 Motivation	4
1.4 Zielsetzung	5
1.5 Hypothesen	5
2 GRUNDLAGEN	9
2.1 Medizinischer Hintergrund: Steigende Anforderungen an das Gesundheitswesen bei der Darmkrebsprävention	9
2.2 Technische und mathematische Grundlagen	11
2.2.1 Durch Markovprozesse modellierbare Systeme	13
2.2.2 Invarianz von Maßen und stationäre Verteilungen in Markovprozessen: Langfristige Stabilität von Systemen	13
2.2.3 Sequenzielle Datenmodellierung mit Markovprozessen	14
2.2.4 Markovketten in diskreter Zeit zur Modellierung von Systemen mit endlichem Zustandsraum	15
2.2.5 Verdeckte Markovmodelle	16
2.2.6 Vorwärtsalgorithmus	17
2.2.7 Rückwärtsalgorithmus	17
2.2.8 CRF als generalisiertes Markovmodell	18
2.2.9 Stochastische Gradientenverfahren für Online-CRFs	19
2.2.10 Kontinuierliche Markovprozesse: Kalmanfilter zur Approximation linearer dynamischer Systeme	19
2.2.11 Chapman Kolmogorov Gleichung	20
2.2.12 Viterbidekodierung	21
2.2.13 Dynamik von Zustandsfolgen: Potenzgesetze und Kaskaden in Markov-Systemen	23
3 STAND DER FORSCHUNG	25
3.0.1 Kombination verschiedener Features wie Farbraumanalyse oder Bewegungserkennung in einem HMM	27

3.1	Computer Vision - Verarbeitung von Bilddaten	27
3.2	CNN - Konvolutionskernels zur Analyse von Bilddaten.	28
3.2.1	Vision Transformer - Nutzung von Attentionmechanismen für die Bildklassifikation	29
4	LÖSUNGSANSATZ	31
4.1	Konzeptionelles Modell zur Zustandsabschätzung	32
4.1.1	Statistische Herleitung der Featureregeln	34
4.1.2	Vergleich von HMM und CRF im Update-Schritt	36
4.2	Begründung der Entscheidungen innerhalb des Methodikteils	36
5	METHODIK	37
5.1	Systemarchitektur und Überblick	37
5.1.1	Von heuristischen Regeln und Expertensystemen zur probabilistischen Inferenz	37
5.2	Definition des HMMs	39
5.3	Merkmalsextraktion und Reduktion des Beobachtungsraums	39
5.3.1	Globale Bewegungsschätzung	40
5.4	Zustandsoptimierung mittels Likelihood-Vektor	40
5.5	Definition des CRF	41
5.6	Texturanalyse mit Local Binary Patterns	41
5.6.1	Algorithmus und Rotationsinvarianz	41
5.6.2	Interpretation der Histogramm-Bins	42
5.6.3	Abgeleitete Metriken	42
5.7	Zusammensetzung und Limitationen des Datensets	42
5.8	Reduktion des Labelraums	42
6	ERGEBNISSE	47
6.1	Vergleich der Ergebnisse des HMM sowie des CRF	47
6.2	Analyse der Ergebnisse des Vergleichs von HMM und CRF	47
6.3	Diskussion der Ergebnisse und Implikationen für die Systemarchitektur	47
7	DISKUSSION	51
7.0.1	Ausblick auf Weltmodelle	52
I	ANHANG	
A	BOXPLOTS DER MERKMALE	57

ABBILDUNGSVERZEICHNIS

Abbildung 4.1	Visualisierung der statistischen Entscheidungsregeln, die in der Generation der Featureregeln genutzt werden definieren.	33
Abbildung 5.1	Systemarchitektur der Featurekalibrierung und des Trainings und CRF sowie der Anlegung von Messvektorprototypen innerhalb des HMM (Der Messvektor wird nicht aktiv in der Inferenz genutzt, diese Komponente existiert für eine spätere Weiterentwicklung.)	38
Abbildung 5.2	Zugrundeliegendes wahres Markovmodell für die Endoskopie bei normaler Anatomie	43
Abbildung 5.3	Boxplots der zentralen Kalibrierungsmerkmale (Hue, Sättigung und LBP-Komplexität) aus dem Datenset.	44
Abbildung 6.1	Vergleich der Modellleistung über alle Videos.	50
Abbildung A.1	Boxplot der Hue-Verteilung.	58
Abbildung A.2	Boxplot der Sättigungs-Verteilung.	58
Abbildung A.3	Boxplot der Value-Verteilung.	58
Abbildung A.4	Boxplot der LAB-L-Verteilung.	58
Abbildung A.5	Boxplot der LAB-a-Verteilung.	59
Abbildung A.6	Boxplot der LAB-b-Verteilung.	59
Abbildung A.7	Boxplot der LBP-Komplexität.	59
Abbildung A.8	Boxplot des LBP-Bins 0.	59
Abbildung A.9	Boxplot des LBP-Bins 1.	60
Abbildung A.10	Boxplot des LBP-Bins 2.	60
Abbildung A.11	Boxplot des LBP-Bins 3.	60
Abbildung A.12	Boxplot des LBP-Bins 4.	60
Abbildung A.13	Boxplot des LBP-Bins 5.	61
Abbildung A.14	Boxplot des LBP-Bins 6.	61
Abbildung A.15	Boxplot des LBP-Bins 7.	61
Abbildung A.16	Boxplot des LBP-Bins 8.	61
Abbildung A.17	Boxplot des LBP-Bins 9.	62

TABELLENVERZEICHNIS

Tabelle 5.1	Kalibrierung der Features: Datenset Multilabel Classification	43
-------------	---	----

Tabelle 5.2	Abbildung der ursprünglichen Labels auf reduzierte Klassen. 45
Tabelle 5.3	Annotierte Frames pro reduzierter Klasse (Datensatz für den Modellvergleich). 45
Tabelle 6.1	Genauigkeit der beiden Modelle über beide Durchläufe. Durchlauf 2 Zeigt den Effekt des Trainings des CRF. 47
Tabelle 6.2	Laufzeitanalyse (inkl. Feature-Extraktion und Diffusion) auf 500 Frames. 48
Tabelle 6.3	Präzision, Recall und F1 über alle Videos. 49

AKRONYME

CNN	Convolutional Neural Network
CRF	Conditional Random Field
HMM	Hidden Markov Model
ViT	Vision Transformer
X	Zustandssequenz
O	Beobachtungssequenz
S	Zustandsraum
s_i	i-ter Zustand
o_t	Beobachtung zum Zeitpunkt t
y_t	Messvektor zum Zeitpunkt t
t	Zeitindex
Z_1	Zeitpunkt des Erreichens des terminalen Ileums
Z_2	Zeitpunkt des Austritts aus dem Körper
$\delta(Z_1, Z_2)$	Zökumrückzugszeit
Q	Query-Matrix im Attention-Mechanismus
K	Key-Matrix im Attention-Mechanismus
V	Value-Matrix im Attention-Mechanismus
d	Skalierungsfaktor der Attention-Berechnung

Die Endoskopie ist ein wesentlicher Bestandteil der modernen medizinischen Diagnostik und hat sich durch Glasfasertechnik und digitale Kameras zu einem sicheren und bewährten Verfahren in der Gastroenterologie entwickelt. [berci2000history] Mit dem Aufkommen von Künstlicher Intelligenz und maschinellem Lernen eröffnen sich in den letzten Jahrzehnten neue Möglichkeiten zur Automatisierung und Verbesserung der Analyse von Endoskopievideos. Insbesondere die bildbasierte Segmentierung profitiert von annotierten Datensätzen und leistungsfähigeren Modellen. Aufgrund der großen Zahl der durchgeführten Darmspiegelung ist die Detektion kolorektaler Adenome ein viel beforschtes Feld. Am weitesten fortgeschritten ist die Detektion kolorektaler Polypen. Dabei wird zwischen computergestützter Detektion (Auffinden) und computergestützter Diagnose (Klassifikation) unterschieden. [okagawa2022artificial]

Während bei Polypen vielversprechende Fortschritte erzielt worden sind, bleiben Endoskopievideos aufgrund von Rauschen, Reflexionen und der Vielfalt an Ereignissen eine Herausforderung. [giordano2025integration] Für den klinischen Alltag sind robuste Vorhersagen und stabile Segmentgrenzen entscheidend, jedoch auch eine gute Recheneffizienz [Ali2020]. Aus diesem Grund soll die Möglichkeit eines hybriden Ansatzes erarbeitet werden. Diese Arbeit fokussiert sich daher auf die Optimierung der Vorhersagen durch Vorselektion und Glättung in kolorektalen Endoskopievideos. Dazu werden Hidden Markov Modelle und Conditional Random Fields (CRF) als Filter für rechenintensive neuronale Netze eingesetzt. Ziel ist eine Reduktion des Suchraums, um die Polypendetektion effizienter und zuverlässiger zu gestalten.

1.1 GEGENSTAND DER FORSCHUNG

1.1.1 Endoskopie als diagnostisches Werkzeug und zur Vorsorge

Endoskopie ist ein weit verbreitetes diagnostisches Werkzeug in der Medizin. Die Untersuchung verschiedener Organe mit einer Kamera bietet erhebliche Vorteile für Patienten und Untersucher und kann große chirurgische Eingriffe vermeiden. Mit verbesserter Bildgebung werden Krankheiten wie Darmkrebs im Mittel früher erkannt, wodurch Risiko und Mortalität in Populationen mit Vorsorgekoloskopie sinken. [doi:10.1056/NEJMo2208375][Doubeni291][doi:10.7326/M17-0723] Verbände wie die Deutsche Gesellschaft für Gastroenterologie, Verdauungs- und Stoffwechselkrankheiten veröffentlichen regelmäßig Leitlinien und

Handlungsempfehlungen zur Anzahl durchgeführter Endoskopien. Um sich als Exzellenzzentrum zu qualifizieren, muss ein Krankenhaus in Deutschland unter anderem mindestens 2500 endoluminale Endoskopien durchführen. [dgav-ev-2015] Dies ist ein erheblicher Aufwand. Angesichts des Ärztemangels wird die Delegation ärztlicher Aufgaben durch Digitalisierung als wichtiges Thema diskutiert, wie eine Umfrage unter 400 angehenden Ärztinnen und Ärzten zeigt. [Junghanns2025Ärztebarometer] In der Gastroenterologie fallen durch die Größe des untersuchten Organs und die Notwendigkeit regelmäßiger Vorsorgekoloskopien große Datenmengen an. Eine häufig durchgeführte Anwendung ist die Koloskopie als Endoskopie des Dickdarms. Sie dient der Vorsorge und der Kontrolle von Darmkrebsvorstufen, zum Beispiel von Adenomen, und deren Wachstum. Polypen können als Vorstufe von Darmkrebs während der Koloskopie im Kolon bis zum Ileum routinemäßig erkannt und entfernt werden. Generell wird die Kolonoskopie in Deutschland deshalb ab 55 Jahren empfohlen. Kolonoskopie ist auch für Patienten mit bekannten Risikofaktoren wie entzündlichen Darmerkrankungen sehr wichtig. [vleggaar-2007] Diese Patienten sollten in Routineuntersuchungen regelmäßig gescreent werden. [arnold-2020]

Die Endoskopie wird seit ihrer flächendeckenden Einführung in vielen Industrieländern weiterentwickelt. Geräte verbessern sich in Auflösung und bildgebenden Verfahren. Die Nutzung spezieller Lichtquellen und Filter (bspw.: narrow-bandwidth-imaging: NBI) wird inzwischen an vielen Standorten zur Hervorhebung von Polypen eingesetzt. [yasushi2016nbi] Auch die Kapselendoskopie bietet als minimalinvasives Verfahren Vorteile. Durch den Durchlauf einer Kapsel im Körper kann sie bei Verdacht auf Blutungsquellen, Dünndarmpolypen oder Morbus Crohn im Dünndarm genutzt werden. Mit dem Aufkommen kostengünstigerer Methoden wie der Kapselendoskopie wird erwartet, dass die Anzahl der zu analysierenden Videos steigt. [koulaouzfidis-2021][8903282] Diese Entwicklung, kombiniert mit steigenden Zahlen kolorektaler Krebsarten, unterstreicht die Notwendigkeit weiterer Forschung zur Verbesserung des Screeningprozesses in Vorbereitung, Durchführung und Nachbearbeitung. [acs-2024, ferlay-2024][kaminski-performance-2017]

1.1.2 KI-gestützte Segmentierung in der Endoskopie

Viele Publikationen argumentieren, dass mit KI-basierter Segmentierung eine Verbesserung der Qualität und Geschwindigkeit in der Endoskopie erfolgen könnte. [ELKarazle2023] In der Methodologie gab es hier mehrere Durchbrüche, die gute Ergebnisse bei der Erkennung von Kolonpolypen aufzeigten. [Fan2020][Dong2021] Hier haben auch Lux et. al. framebasierte Klassifikation demonstriert. Sie schlagen eine regelbasierte Erweiterung durch post-processing zur Segmentierung

vor. Ihre Pipeline basiert beispielsweise auf einer Multilabel-KI, die die Wahrscheinlichkeit der für die aktuelle Endoskopie relevanten Klassen vorhersagt. Ein feinabgestimmtes RegNetX800MF-Modell sagt diese Wahrscheinlichkeiten Bild für Bild voraus; daraus entsteht eine zeitliche Segmentierung des Videos. [lux-2023] Einsatz solcher Systeme zur Entscheidungsunterstützung wurde von Hann et al. evaluiert, wobei diese die Vorteile nennen, jedoch in ihrer Untersuchung Hinweise auf negative Effekte wie eine mögliche Abnahme der Konzentration der Untersucher finden, die dazu führen kann, dass die Anzahl der gefundenen Darmpolypen sinkt. [hann_entscheidungsunterstützung_2025]

1.1.3 Herausforderungen bei der KI basierten Segmentierung von Endoskopievideos

Die derzeitige Segmentierungspipeline verwendet eine Glättungsfunktion zur Nachbearbeitung der bildbasierten Vorhersagen. Der Hauptgrund ist, dass Segmente falsch unterbrochen werden können. Dies kann beispielsweise passieren, wenn Lichtreflexionen im Video sichtbar sind oder wenn der Wasserstrahl des Endoskops im Bild Reflexionen verursacht. Auch Artefakte durch mangelnde Spülung der Patienten können als Störfaktoren auftreten. Probleme treten insbesondere bei Ein- und Austritt des Endoskops in den Körper oder bei der Spülung des Kolons nicht korrekt abgeführt Patienten auf, da sich hier die Lichtverhältnisse rapide ändern. Bei der Detektion von Artefakten in medizinischen Bilddaten, nannten Ali et. al. die „(i) Konsistenz, (ii) Genauigkeit der Vorhersage, und die (iii) computationale Effizienz“ als Voraussetzungen für den klinischen Einsatz. [Ali2020]

1.2 PROBLEMSTELLUNG

Die aktuelle Implementierung der Videosegmentierung für Endoskopieaufnahmen weist bei Inbetrachtung eines klinischen Einsatzes mehrere kritische Probleme auf, die eine zuverlässige Qualitätsmessung behindern:

- Die derzeitige Glättungsfunktion zur Nachbearbeitung der Framebasierten Vorhersagen ist unzureichend für eine präzise Bestimmung der Segmentgrenzen
- Die Anonymität der Patienten wird durch unpräzise Segmentierung gefährdet, da „Outside“-Frames oft Personen zeigen
- Die Durchführung KI-gestützter Klassifizierung auf Frames mit niedriger Bildqualität durch Spülung oder Lichtreflexionen führt zu falsch positiven und falsch negativen Ergebnissen und verbraucht Rechenzeit.

Konkret sollen in dieser Arbeit folgende aus dem Einsatz der Multi-labelklassifikation bekannten Probleme betrachtet werden:

- **Problem P1: Fehlende Berücksichtigung visueller Merkmale**
Viele Methoden zur Nachbearbeitung berücksichtigen keine zusätzlichen visuellen Informationen (wie Farbinformationen), die zur Verbesserung der Segmentierungsgenauigkeit von CNN-Vorhersagen beitragen könnten.
- **Problem P2: Mangelnde Robustheit gegenüber durch Störungen ausgelöste falsch positive Ergebnisse**
Systeme zur Endoskopiesegmentierung sind anfällig für Störungen durch Lichtreflexionen und Wasserartefakte, die zu Segmentierungsunterbrechungen und falsch positive Ergebnisse bei der Detektion relevanter Merkmale, wie Adenome führen.

Diese Probleme stehen im engen Zusammenhang mit den in Abschnitt 1.4 beschriebenen Zielen.

1.3 MOTIVATION

Die Lösung der beschriebenen Probleme ist aus folgenden Gründen von hoher Relevanz:

- **Effizienzsteigerung in der Endoskopie:** Es wird vermutet, dass die automatisierte und zuverlässige Segmentierung sowohl Ärzte bei der Dokumentation entlasten kann als auch die Frameklassifikation durch eine Reduktion des Suchraums beschleunigt werden kann.
- **Datenschutz und Anonymisierung:** Präzise Segmentierung der Bereiche außerhalb des Körpers ist wichtig für die Anonymisierung von Endoskopievideos. Da diese Bereiche oft Personen zeigen, sind diese Datenschutzrechtlich relevant und stehen einer Veröffentlichung im Weg.

Nutznieser dieser Arbeit:

- Gastroenterologen und Endoskopiepersonal profitieren von einer reduzierten Videolänge bei der
- Patienten erhalten durch bessere Qualitätskontrolle eine sicherere Behandlung
- Die Forschungsgruppe ColoReg erhält optimierte Algorithmen für ihre Segmentierungspipeline
- Die medizinische Informatik profitiert von methodischen Erkenntnissen zum kombinierten Einsatz von statistischen Modellen mit Deep Learning Modellen

Die steigenden Zahlen von Darmkrebserkrankungen [acs-2024, ferlay-2024] und die zunehmende Anzahl von Endoskopievideos durch neue Methoden wie die Kapselendoskopie [koulouzidis-2021] unterstreichen die Dringlichkeit, automatisierte Analysesysteme kontinuierlich zu verbessern.

1.4 ZIELSETZUNG

Das Ziel dieser Masterarbeit ist die Entwicklung und Evaluation verbesserter Nachbearbeitungsverfahren für die framebasierte Segmentierung von Endoskopievideos. Im Idealfall kann das System die Nutzung von Frameklassifizierung ergänzen. Die Minimalanforderung an ein erfolgreiches System ist die zuverlässige Klassifizierung der Videosegmente außerhalb und vor dem Eintreten des Endoskops in den Körper. Aus Datenschutzgründen muss diese Region des Videos sicher entfernt werden. Auch die Erkennung von Regionen niedriger Bildqualität soll mittels des Modells möglich werden. Zudem ist der Informationsgehalt aus dieser Region des Videos gleich null. So kann die Dokumentation und Klassifikation der interessanten Regionen durch eine Reduktion des Suchraums beschleunigt werden.

Im folgenden werden detailliert die Ziele der Arbeit ausgeführt

Ziele zur Lösung von Problem P₁ (Unzuverlässige Segmentgrenzbestimmung):

- **Ziel Z_{1.1}:** Implementierung eines HMM und eines CRF zur Klassifikation von wenig aussagekräftigen Regionen des Videos.

Ziel zur Lösung von Problem P₂ (Fehlende Berücksichtigung visueller Merkmale):

- **Ziel Z_{2.1}:** Verbesserung der Robustheit gegenüber Lichtreflexionen und Wasserartefakten

Ziel zur Lösung von Problem P₃ (Fehlende Berücksichtigung visueller Merkmale):

- **Ziel Z_{3.1}:** Bewahrung der Funktionalität der ursprünglichen Glättungsfunktion bei gleichzeitiger Verbesserung der Genauigkeit

Übergeordnetes Ziel:

- **Ziel Z_{3.1}:** Systematischer Vergleich von HMM und CRF Ansätzen hinsichtlich Genauigkeit, Robustheit und Recheneffizienz für die Vorbereitung der Endoskopiesegmentierung

1.5 HYPOTHESEN

Die Forschungsfrage dieser Arbeit lautet, ob die Einführung von Nachbearbeitungsschritten die Qualität der „Außerhalb“-Vorhersage verbessert. Daraus ergibt sich als methodischer Kern, die verwendeten Frames

für die Segmentation zu filtern. Der Vollständigkeit halber sollen auch die anderen farbrelevanten Labels (wie „Blut“, „Instrument“, „Narrow Band Imaging“ und „Niedrige Bildqualität“) in die Analyse einbezogen werden, um die allgemeine Leistungsfähigkeit der Segmentierung zu vergleichen.

Aufgaben zur Erreichung der Ziele:

Aufgaben zu Ziel Z1.1 (HMM-Implementierung):

- **Aufgabe A1.1.1:** Analyse der aktuellen Glättungsfunktion und ihrer Schwächen
- **Aufgabe A1.1.2:** Design und Implementierung eines HMM-basierten Nachbearbeitungsalgorithmus
- **Aufgabe A1.1.3:** Integration des HMM-Ansatzes in die bestehende Segmentierungspipeline

Aufgaben zu Ziel Z1.2 (CRF-Implementierung):

- **Aufgabe A1.2.1:** Konzeption eines CRF-Modells für die Endoskopiesegmentierung
- **Aufgabe A1.2.2:** Implementierung und Training des CRF-Ansatzes
- **Aufgabe A1.2.3:** Optimierung der CRF-Parameter für die Endoskopiedomäne

Aufgaben zu Ziel Z2.1 (Integration visueller Merkmale):

- **Aufgabe A2.1.1:** Extraktion und Analyse von Farbmerkmalen aus Endoskopieframes
- **Aufgabe A2.1.2:** Integration der Farbinformationen in die HMM- und CRF-Modelle

Aufgaben zu Ziel Z3.1 (Robustheit):

- **Aufgabe A3.1.1:** Identifikation und Charakterisierung von Störungen (Lichtreflexionen, Wasser)
- **Aufgabe A3.1.2:** Entwicklung robuster Merkmale zur Störungsunterdrückung

Aufgaben zu Ziel Z4.1 (Evaluation):

- **Aufgabe A4.1.1:** Systematische Evaluation der HMM- und CRF-Ansätze gegen die CNN-basierte Segmentierung sowie eine Annotation
- **Aufgabe A4.1.2:** Bewertung der Recheneffizienz und praktischen Anwendbarkeit

Idealerweise würde das Ergebnis darin bestehen, die Start- und Endzeitstempel der Segmente zuverlässiger zu setzen. Bei Messungen sollte dies zu positiven Änderungen beim Vergleich der Vorhersage des Modells mit annotierten Start- und Endzeiten sowie mit der ursprünglichen Glättungsfunktion unter Verwendung des gleitenden Durchschnitts der Vorhersagen führen.

In diesem Kapitel werden die medizinischen und technischen Grundlagen erläutert, die für das Verständnis der Arbeit notwendig sind. Zunächst werden die medizinischen Hintergründe des behandelten Problems eingeordnet. Anschließend werden das technische Fundament der Segmentierung sowie gängige Bildgebungsverfahren behandelt, die zur Lösung des Problems eingesetzt werden können. Dabei werden Markovmodelle mit Methoden der Signal und Bildverarbeitung kombiniert, um eine robuste Segmentierung von Endoskopievideos zu ermöglichen. Die der technischen Implementierung zugrundeliegenden mathematischen Hintergründe und Theoreme werden ebenfalls vorgestellt, um die theoretische Basis der Arbeit zu untermauern.

2.1 MEDIZINISCHER HINTERGRUND: STEIGENDE ANFORDERUNGEN AN DAS GESUNDHEITSWESEN BEI DER DARMKREBSPRÄVENTION

Endoskopie ist eine der zentralen Möglichkeiten zur Behandlung und Diagnose in der Therapie von Darmkrebs, einer der häufigsten und tödlichsten Krebsarten. [labianca2010-colon-cancer] Nicht von der Hand zu weisen sind dabei die zeitaufwändige Durchführung und Dokumentation rund um die Durchführung von Endoskopien. Aus diesem Grund ist es der Gastroenterologie ein ständiges Anliegen, die Qualitätssicherung bei Darmspiegelungen zu verbessern. Ein Beispiel für einen Qualitätsindikator ist die Zökumrückzugszeit. Klinische Studien konnten eine Korrelation der Rückzugszeit mit der Adenomdetektionsrate und das Risiko übersehener Läsionen steigt mit kürzerer Rückzugszeit. Es wird vermutet, dass die Darmschleimhaut bei kürzerer Zeit häufiger nicht vollständig eingesehen wird [vilmann-2022]. Dieses Beispiel zeigt, dass die Einhaltung sinnvoller Qualitätskriterien die Behandlungsqualität steigern kann. Hierbei muss jedoch bei jeder Maßnahme abgewägt werden, ob der Mehraufwand tatsächlich ausreichend nützlich für die Behandlungsqualität ist. Die Europäische Gesellschaft für Gastroenterologie (ESGE) hat zu diesem Thema und zur Verbesserung der Qualität von Kolonoskopien einige Forschungsanstöße herausgegeben.

”

1. Vorbereitung der Prozedur

- Welche Art von Intervention verbessert die Rate einer adäquaten Darmvorbereitung?

- Wie viel Zeit sollte für Screening- und diagnostische Koloskopien eingeplant werden?

2. Vollständigkeit der Prozedur

- Welchen Nutzen hat die Dokumentation der Zökumintubation nur im schriftlichen Bericht im Vergleich zu einem schriftlichen *und* fotografischen Bericht?

3. Identifikation von Pathologien

- Welcher Zielwert gilt für die Adenomdetektionsrate?
- Welches Leistungsmaß spiegelt die Identifikation von Pathologien außerhalb des CRC-Screening-/Überwachungssettings wider?

4. Wie verhalten sich diagnostische Ausbeute (und Intervallkarzinomrate) in Abhängigkeit von einer steigenden Zökumintubationsrate?

5. Management von Pathologien

- Was ist die verlässlichste und praktikabelste Methode, um die Vollständigkeit der Polypentfernung zu messen?
- Wie wirksam sind Zusatztechniken/-skalen (Chromendoskopie, Paris-Klassifikation, Tätowierung von Resektionsstellen) im Management von Pathologien?

6. Komplikationen

- Was ist die verlässlichste und praktikabelste Methode, um Komplikationsraten zu überwachen?
- Trägt die Überwachung dazu bei, Komplikationsraten zu senken?

“ [kaminski-performance-2017]

Im Rahmen der Qualitätssicherung sollen Merkmale der Koloskopie videodokumentiert werden: „Eine Bilddokumentation der Bauhin’schen Klappe (Übergang des Dünndarms in den Dickdarm) sowie des Cöcumbodens (Abgang des Appendix) ist im Rahmen der Qualitätssicherung notwendig. Auch Polypen werden vor und nach der Abtragungen videodokumentiert.“ [Beyer2022]. Qualitätsanforderungen wie diese sind aufgrund der hohen Zahl der Kolonoskopien mit viel Aufwand verbunden. Die zuverlässige Erkennung Regionen mit erhöhter Wahrscheinlichkeit für relevante Befunde im Video ist Teil der medizinischen Forschung mit künstlicher Intelligenz. Insbesondere ist die Erkennung von Polypen von besonderem Interesse. Diese wachsen als Vorstufe von potenziell bösartigen Tumoren an der Darminnenwand. Sie können aus verschiedenen Gründen und in verschiedenen Darmteilen auftreten, sind jedoch besonders als Frühmerkmal einer möglichen Diagnose von Darmkrebs interessant und deshalb wenn möglich vollständig

zu erkennen. [doi:10.7326/0003-4819-157-4-201208210-00002] Weiter kompliziert wird die Erkennung und Einschätzung von Polypen dadurch, dass es verschiedene Stufen ihrer Ausprägung sowie verschiedene genetische Ursachen für sie gibt. [PickhardtColonPolyps] Während bei einigen kolorektalen Polypen eine Darmblutung als Symptom auftritt, die zumeist eine schnelle Diagnose ermöglicht, sind andere Polypen asymptomatisch und werden nur zufällig bei einer routinemäßigen Darmspiegelung entdeckt. Besonders bei diesen Fällen kann das Risiko bestehen, dass Polypen übersehen werden. Unterschieden wird hierbei zwischen hochgradigen und niedergradigen Dysplasien. Diese Stufen bezeichnen den Grad der Zellveränderung in der Region des Polypen. Besonders bei höhergradigen Dysplasien besteht das Risiko, dass ein maligner Polyp vorliegt. Definitiv kann dies durch den Nachweis karzinogener Zellen innerhalb eines Polypen festgestellt werden. Hierbei handelt es sich um eine Aufgabe für die Pathologie, die nach vollständiger Entfernung des betroffenen Gewebes erfolgen kann. [Colucci261] Da durch den Einsatz einer zuverlässigen automatischen Erkennung dieser Vorkommnisse innerhalb des Darms eine erhebliche Beschleunigung dieses Prozesses möglich wäre, wird in diesem Bereich bereits seit Jahren geforscht. [talukder-2022]

Um die Anwendung von automatisierter Dokumentation erfolgreich in den Arbeitsalltag zu integrieren, soll im folgenden erläutert werden welche technischen und mathematischen Prinzipien in die Lösung der Optimierung der Vorverarbeitung von Endoskopievideos verwendet wurden. Aufgrund der sequenziellen Natur der Frames von Endoskopievideos ist die Wahl der Methodik auf zwei auf Markovketten basierenden Modellklassen gefallen. Diese sind das CRF und HMM.

2.2 TECHNISCHE UND MATHEMATISCHE GRUNDLAGEN

Dieses Kapitel wird die Herangehensweise an die mathematische Modellierung der Segmentierung von Endoskopievideos erläutern. In diesem Kontext soll später im Kapitel Methodik herausgearbeitet werden, welche Modelle sich für eine statistisch haltbare Bewertung von Frameregionen eignen. Da es sich bei einer Endoskopie, wie in Lux et al. [lux-2023] demonstriert, um eine Untersuchung handelt, die sich in Phasen beziehungsweise Zustände einteilen lässt, wurde der Fokus auf zustandsbasierte Modelle wie Markovmodelle gelegt.

2.2.0.1 Markovprozesse: Eine Methode, um abhängige Variablen probabilistisch zu quantisieren

„Wir betrachten ein zufälliges dynamisches System. Sei $S : \mathbb{R} \rightarrow \mathbb{R}$ ein dynamisches System und definieren einen stochastischen Prozess $\{X_n\}_{n \geq 0}$ durch $X_{n+1} = S(X_n) + Y_n$, wobei $Y_0, Y_1, \dots$ unabhängige Zufallsvariablen mit Werten in $\mathbb{R}$ sind, die jeweils die gleiche Dichte g

haben, und X_0 und $\{Y_n\}_{n \geq 0}$ unabhängig sind. Dann ist der stochastische Prozess $\{X_n\}$ ein Markovprozess.“ [KhalilGhaffari2023] Markovprozesse sind laut dieser Definition Systeme aus Zuständen, die sich über die Zeit verändern. Sie dürfen dabei nur von dem aktuellen Zustand abhängen und nicht von den vorherigen Zuständen. Die Definition bezieht sich auf ein Stochastisches System und sieht deshalb eine Normierung der Werte im Bereich 0 bis 1 vor. Die Zustände des Systems werden durch die Zufallsvariablen X_n beschrieben.

Das Konzept der Markovprozesse stammt aus der Arbeit von A. A. Markov. Insbesondere interessant ist hier die Publikation „Beispiel von statistischer Forschung auf einem Text von ‚Eugene Onegin‘, der die Interkonnektivität abhängiger Versuche in einer Kette klassifiziert.“ [markov1913onegin]. Anhand eines Gedichts und der Verteilung der Konsonanten und Vokale untersuchte Markov hier, ob durch vielfache Wiederholung eines Zufallsexperiments, bei dem die Versuche voneinander abhängig sind, eine statistische Vorhersage getroffen werden kann. Dieser empirische Beweis greift eine frühere Publikation seinerseits auf, die theoretisch darlegt, dass das Gesetz der großen Zahlen auch auf abhängige Zufallsvariablen anwendbar ist. Durch empirisches Messen der Häufigkeiten der Variablen erfasste Markov eine Übergangswahrscheinlichkeit.

$$p_{ij} = P(X_{n+1} = j \mid X_n = i), \quad \text{mit} \quad \sum_j p_{ij} = 1. \quad (2.1)$$

Diese konnte er im Nachgang einsetzen, um über diese Wahrscheinlichkeiten wiederum eine Buchstabenfolge zu generieren, bei der die Anzahl der Konsonanten und Vokale wieder auf einem Niveau einpendelte, das mit dem russischen Originaltext vergleichbar war. Durch Markovs späteren empirischen Beweis seiner theoretischen Grundlagenpublikation [markov1906extension] zeigte er, dass auch abhängige Variablen in oft wiederholten Zufallsexperimenten messbare Gesetzmäßigkeiten aufzeigen können. Diese Idee wurde weiterentwickelt, um durch passende Modelle effiziente Vorhersagen über zukünftige Ereignisse treffen zu können. Seine Arbeit hat bis heute großen Einfluss und begründete die Klasse der Markovprozesse.

In seinem Einführungswerk beschreibt A. W. Drake Markovprozesse in diskreter Zeit und mit diskreter Zustandsmenge. Er definiert sie allgemein als Kette von Zuständen S , deren zukünftige Entwicklung nur vom aktuellen Zustand abhängt und deren Übergänge durch Übergangswahrscheinlichkeiten bestimmt werden. Eine Bedingung für das Vorliegen eines Markovprozesses wird so definiert als

$$P(X_{n+1} = x_{n+1} \mid X_n = x_n, X_{n-1} = x_{n-1}, \dots, X_0 = x_0) = P(X_{n+1} = x_{n+1} \mid X_n = x_n) \quad (2.2)$$

. Weitergehend gilt als zweite Eigenschaft der Übergangswahrscheinlichkeiten, dass die ausgehenden Wahrscheinlichkeiten eines Zustands

sich zu eins addieren, damit es sich um eine vollständige Abbildung aller möglichen Zustände handelt.

$$\sum_j P_{ij} = 1. \quad (2.3)$$

Wobei P_{ij} die Wahrscheinlichkeit beschreibt, dass das System, nachdem der aktuelle Zustands S_i ist, in den nächsten Zustand S_j übergehen wird. [drake88]

Generalisiert kann davon gesprochen werden, dass ein Markovprozess sich aus dem Zustandsraum Ω zusammensetzt, der alle möglichen Zustände des Systems umfasst. Die einzelnen Zustände S_i oder ω sind Elemente dieses Zustandsraums Ω . Genauso gilt für die Wahrscheinlichkeiten $P(X_n)$, dass sie Elemente des Wahrscheinlichkeitsraums $\mathcal{P}$ sind. Auch die Zeit $\{n\}$, in der sich die Zustände ändern, kann als Element eines Zeitraums $\mathcal{T}$ betrachtet werden. Somit lässt sich ein Markovprozess als Tripel $(\Omega, \mathcal{P}, \mathcal{T})$ beschreiben.

2.2.1 Durch Markovprozesse modellierbare Systeme

Markovprozesse eignen sich für Systeme, bei denen die zukünftige Entwicklung mit hinreichender Genauigkeit nur vom aktuellen Zustand abhängt. Beispiele sind Warteschlangensysteme, diskrete Entscheidungsprozesse, Zustandsfolgen in Texten oder Sequenzen in der Bildverarbeitung. Die Eignung hängt davon ab, wie der Zustandsraum gewählt wird und ob die Markoveigenschaft in der Anwendung näherungsweise erfüllt ist.

2.2.2 Invarianz von Maßen und stationäre Verteilungen in Markovprozessen: Langfristige Stabilität von Systemen

Ein häufig auftretendes Problem bei der Modellierung von kontinuierlichen Systemen ist es, dass ein System, wenn es langfristig betrachtet wird oftmals eine stationäre Verteilung erreicht. Das beschriebene Phänomen kann gut am bekannten Problem des Ruin des Spielers, des Gamblers Ruin, erklärt werden. Dieses berühmte Problem trägt den Namen, da bei der Analyse von Glücksspielen entdeckt wurde, dass bekannte Glücksspiele wie Roulette oder Poker, die wiederholt mit einem jede Runde reinvestierten Startkapital gespielt werden, langfristig immer der finanzielle Ruin eines Spielers führen. Es kann dabei durch den Aufbau des Spiels, das Startkapital sowie Einsatz und Strategie die Länge des Spiels sowie das Endergebnis beeinflusst werden. Wie J.L. Coolidge zeigen konnte, ist der genaue Zeitpunkt des Ruins eines Spielers oder der Bank unbekannt, liegt jedoch stets innerhalb eines definierbaren Limits. Werden die Regeln des Spiels von der Bank vorgegeben, kann über geschicktes Anpassen der Variablen der Gewinn

des Spielers bei Spiel bis zum Erschöpfen des Budgets sogar unmöglich gemacht werden. [coolidge1909gamblers]

Auch der Gamblers Ruin kann als Markovkette betrachtet werden. Diese kann verschiedene Zustände annehmen die die aktuelle Gewinn-situation abbilden. Am Startzustand liegt auf keiner Seite ein Verlust vor. Nach Start des Spiels können vier weitere Zustände eintreten: Einmal gewinnt die Bank bei fortlaufendem Spiel, einmal der Spieler. Diese Markovkette zeichnet sich zudem durch zwei absorbierende Ränder aus, die den Ruin der jeweiligen Seite darstellen. Aus jedem dieser Zustände kann das System nicht mehr entkommen, da das Kapital erschöpft ist. Der einzige Weg diese Situation zu umgehen wäre eine nachträgliche Steigerung des Kapitals einer Seite.

Angenommen μ ist die Verteilung des Gewichts $\omega \in \Omega$ eines Objekts zu einem Zeitpunkt t , wobei Ω die Menge aller möglichen Gewichte und damit der Zustandsraum ist. Es wird von einem Gewicht der Kante i zu einem Gewicht der Kante j mit der Wahrscheinlichkeit P_{ij} übergegangen. Wenn der Zustand ω zufällig und mit der Verteilung μ verteilt ist, und die angenommene Wahrscheinlichkeit für μ gleich P_μ ist, dann wird eine P invariante Verteilung $P_\mu = \mu$ genannt. Die theoretische Existenz solcher invarianten Maße wird unter geeigneten Bedingungen gezeigt. [Lester1966]

Aus dieser Definition der Verteilung und ihrer Konvergenz in Markovsystemen, in denen die Anzahl der Versuche gegen unendlich geht, entsteht ein messbares Kriterium für die Bewertung von Markovketten. Um zu bestimmen, wie sich ein System langfristig verhält, muss festgestellt werden, ob es Ergodizität aufweist. Prozesse gelten als ergodisch, wenn es einen stabilen Zustand gibt, in den das System konvergiert, unabhängig vom Anfangszustand. [MeynTweedie1993]

Wenn die wahre Verteilung μ und die dazugehörige Übergangswahrscheinlichkeit P_μ in der Praxis nicht bekannt sind, wird eine geschätzte Verteilung π und die dazugehörige Übergangswahrscheinlichkeit P_π genutzt. Ein stabiler Schätzer zielt darauf ab, dass π unter wiederholter Anwendung der Übergänge möglichst konsistent bleibt.

2.2.3 Sequenzielle Datenmodellierung mit Markovprozessen

Die Modellierung sequenzieller Daten ist ein wichtiger Aspekt in vielen Bereichen der Informatik und Statistik, insbesondere in der Verarbeitung natürlicher Sprache, Zeitreihenanalyse und Bioinformatik. Sequenzielle Daten bestehen aus einer geordneten Folge von Elementen, bei denen die Reihenfolge der Elemente eine entscheidende Rolle spielt. Beispiele für sequenzielle Daten sind Textdokumente, DNA Sequenzen und Zeitreihen von Messwerten. Basierend auf der Entdeckung von Markov, wurden hierfür vielfältige Erweiterungen mit weitreichenden Anwendungen konzipiert. Markovmodelle zielen darauf ab, die Abhängigkeiten zwischen aufeinanderfolgenden unabhängigen Zuständen in

einer Sequenz zu erfassen. Dafür werden Übergangsmatrizen gebildet, deren Felder die Wahrscheinlichkeit für den Übergang des Systems zu einem anderen Zustand beschreiben.

Wenn die Übergangswahrscheinlichkeiten in einer Matrix P zusammengefasst werden spricht man von einer Übergangsmatrix. Hierbei geben die Einträge P_{ij} die Wahrscheinlichkeit an, vom Zustand i in den Zustand j überzugehen. Die Matrix P wird als Übergangsmatrix bezeichnet und hat die Eigenschaft, dass die Summe der Einträge in jeder Zeile gleich 1 ist, da die Gleichung der Zeile die gesamten Übergangswahrscheinlichkeiten von einem Zustand zu allen möglichen Zuständen repräsentiert.

Für die Übergangsmatrix für einen Schritt P gilt per Definition:

$$P_{ij} = P(X_{t+1} = j \mid X_t = i). \quad (2.4)$$

Für eine Übergangswahrscheinlichkeit bei zwei Schritten $P(X_{t+2} = j \mid X_t = i)$ müssen wir einen Zwischenzustand k beachten:

$$P(X_{t+2} = j \mid X_t = i) = \sum_k P(X_{t+1} = k \mid X_t = i) \cdot P(X_{t+2} = j \mid X_{t+1} = k). \quad (2.5)$$

In der Definition nimmt das Modell ein vollständig abgebildetes stochastisches Zufallsexperiment an. Es wird zudem davon ausgegangen, dass die Zustände des Systems vollständig beobachtbar sind. Einer einfachen Definition folgend, müsste so für jedes Label y_i eines Frames x_i die Wahrscheinlichkeit $P(y_i \mid x_i)$ für die Wahrscheinlichkeit das nächste Label x_i zu erreichen modelliert werden. [drake88]

2.2.4 Markovketten in diskreter Zeit zur Modellierung von Systemen mit endlichem Zustandsraum

Eine Markovkette ist ein Spezialfall eines Markovprozesses mit diskreten Zeitpunkten und endlichem Zustandsraum. Sei $S = \{s_1, s_2, \dots, s_N\}$ die Menge der möglichen Zustände. Die Folge $\{X_t\}_{t \geq 0}$ heißt Markovkette, wenn für alle $t \geq 0$ gilt:

$$P(X_{t+1} = s_j \mid X_t = s_i, X_{t-1}, \dots, X_0) = P(X_{t+1} = s_j \mid X_t = s_i). \quad (2.6)$$

Die Wahrscheinlichkeiten $P_{ij} = P(X_{t+1} = s_j \mid X_t = s_i)$ bilden die Übergangsmatrix $P \in \mathbb{R}^{N \times N}$. Jede Zeile von P ist normiert, d. h.

$$\sum_{j=1}^N P_{ij} = 1, \quad \forall i. \quad (2.7)$$

ANFANGSVERTEILUNG. Die Wahrscheinlichkeiten, mit denen das System in einem Zustand startet, werden durch den Vektor $\pi = (\pi_1, \dots, \pi_N)$ beschrieben, wobei $\pi_i = P(X_0 = s_i)$ gilt.

N SCHRITT ÜBERGÄNGE. Für $n > 1$ ergibt sich die Anzahl der Felder der n Schritt Übergangsmatrix durch Potenzieren:

$$P^{(n)} = P^n. \quad (2.8)$$

STATIONÄRE VERTEILUNG. Eine Verteilung π^* heißt *stationär*, wenn sie unter Anwendung der Übergangsmatrix invariant bleibt:

$$\pi^* = \pi^* P. \quad (2.9)$$

BEISPIEL. Für ein zweizuständiges System mit Zuständen „Innen“ und „Außen“ im Endoskopievideo sei

$$P = \begin{pmatrix} 0.9 & 0.1 \\ 0.3 & 0.7 \end{pmatrix}.$$

Dann beschreibt $P_{12} = 0,1$ die Wahrscheinlichkeit, dass ein Frame vom Typ „Innen“ im nächsten Schritt zu „Außen“ wechselt.

2.2.5 Verdeckte Markovmodelle

Markovmodelle sind eine Klasse von statistischen Modellen, die verwendet werden, um Systeme zu modellieren, die sich über die Zeit verändern. Sie basieren trotzdem auf der Markovannahme, die besagt dass der zukünftige Zustand eines Systems nur vom aktuellen Zustand abhängt und nicht von den vorherigen Zuständen.

Die Modelle werden als „verdeckte“ Markovmodelle bezeichnet, wenn die zugrunde liegenden Zustände nicht direkt beobachtet werden, sondern nur durch beobachtbare Ausgaben oder Emissionen inferiert werden.

Generell handelt es sich bei HMMs um generative Modelle, d. h. sie modellieren die gemeinsame Verteilung

$$P(X, O),$$

wobei X die Folge der versteckten Zustände und O die Folge der Beobachtungen bezeichnet.

Da die tatsächliche Wahrscheinlichkeit des Zustandes sowie der Grund für den aktuellen Zustand dem Modell nicht bekannt ist, beschreibt das Modell die Wahrscheinlichkeit für die Beobachtungen, also den beobachtbaren Raum, dessen Ursprung der eigentliche Zustandsraum ist. Dieser clevere Trick erlaubt den Einsatz des HMM zur Schätzung wiederkehrender Muster in sonst schwer zu beschreibenden Daten. Die Sequenz des HMMs kann über den Vorwärts- sowie den Rückwärtsalgorithmus beschrieben werden.

2.2.6 Vorwärtsalgorithmus

Die Vorwärtsvariable $\alpha_t(i)$ ist als die Wahrscheinlichkeit der partiellen Observationssequenz $O = \{o_1, o_2, \dots, o_t\}$ und des Zustands s_i zur Zeit t , bei dem gegebenen Modell λ :

$$\alpha_t(i) = P(o_1, o_2, \dots, o_t, s_t = s_i | \lambda)$$

definiert.

1. Initialisierung:

$$\alpha_1(i) = \pi_i b_i(o_1), \quad 1 \leq i \leq N$$

2. Rekursion:

$$\alpha_{t+1}(j) = \left[\sum_{i=1}^N \alpha_t(i) a_{ij} \right] b_j(o_{t+1}), \quad 1 \leq t \leq T-1, \quad 1 \leq j \leq N$$

3. Terminierung:

$$P(O|\lambda) = \sum_{i=1}^N \alpha_T(i)$$

2.2.7 Rückwärtsalgorithmus

Die Rückwärtsvariable $\beta_t(i)$ ist die Wahrscheinlichkeit, die restliche Teilsequenz von $t+1$ bis zum Ende zu beobachten, gegeben, dass das System zum Zeitpunkt t im Zustand s_i ist.

1. Initialisierung:

$$\beta_T(i) = 1, \quad 1 \leq i \leq N$$

(Die Wahrscheinlichkeit am Ende ist per Definition 1)

2. Rekursion:

$$\beta_t(i) = \sum_{j=1}^N a_{ij} b_j(o_{t+1}) \beta_{t+1}(j), \quad t = T-1, T-2, \dots, 1, \quad 1 \leq i \leq N$$

3. Terminierung:

$$P(O|\lambda) = \sum_{i=1}^N \pi_i b_i(o_1) \beta_1(i)$$

Diese allgemeingültige Definition sowie die Kombination des Algorithmus mit kreativer Definition der verwendeten Observationen ermöglicht eine effiziente Nutzung von Markovmodellen im Bereich des überwachten Lernens, zum Beispiel in der Bioinformatik. [Ma2026HMM]

2.2.8 CRF als generalisiertes Markovmodell

Conditional Random Fields beschreiben eine Klasse von Modellen, mit denen sich Übergangswahrscheinlichkeiten darstellen lassen. Generell handelt es sich bei CRF um diskriminative Modelle: Es wird direkt die bedingte Wahrscheinlichkeit

$$P(Y | X)$$

der Ausgabevariablen Y gegeben die Eingabevariablen X modelliert, anstatt der gemeinsamen Wahrscheinlichkeit $P(X, Y)$.

CRF lassen sich als diskriminatives Analogon zu generativen HMMs verstehen. Während HMMs $P(X, O)$ modellieren, werden CRF auf $P(X | O)$ und sind dadurch robuster gegenüber komplexen Abhängigkeiten in den Eingangsdaten. Verdeckte Markovmodelle beinhalten, wie im vorigen Abschnitt erläutert, die Annahme, dass aufgrund des vorherigen versteckten Zustands das System vorhergesagt werden kann. Hierfür müsste das System durch die Menge der versteckten Zustände vollständig beobachtbar und adäquat abbildbar sein. Ein Conditional Random Field erlaubt es, diese Annahmen zu lockern und Abhängigkeiten zwischen Beobachtungen explizit zu modellieren. Vgl.: [10.5555/645530.655813]

GRADIENT DER MARGINALEN LOG-LIKELIHOOD FÜR CRFS

Die Ableitung der marginalen Log-Likelihood $\ell(\theta)$ nach einem Parameter θ_{pk} lässt sich durch die Erwartungswerte der Merkmalsfunktionen ausdrücken. Unter Verwendung der Identität $\frac{\partial \ell}{\partial \theta} = \frac{1}{p(y|x)} \frac{\partial p(y|x)}{\partial \theta}$ ergibt sich:

$$\frac{\partial \ell}{\partial \theta_{pk}} = \sum_{\mathbf{w}} p(\mathbf{w}|\mathbf{y}, \mathbf{x}) \frac{\partial}{\partial \theta_{pk}} \log p(\mathbf{y}, \mathbf{w}|\mathbf{x}) \quad (2.10)$$

Nach Einsetzen der Potentialfunktionen und Vereinfachung erhält man die Differenz zweier Erwartungswerte:

$$\begin{aligned} \frac{\partial \ell}{\partial \theta_{pk}} = & \underbrace{\sum_{c \in C_p} \sum_{\mathbf{w}'_c} p(\mathbf{w}'_c|\mathbf{y}, \mathbf{x}) f_k(\mathbf{y}_c, \mathbf{x}_c, \mathbf{w}'_c)}_{\text{Erwartungswert über latente Variablen (geklemmt)}} \\ & - \underbrace{\sum_{c \in C_p} \sum_{\mathbf{w}'_c, \mathbf{y}'_c} p(\mathbf{w}'_c, \mathbf{y}'_c|\mathbf{x}_c) f_k(\mathbf{y}'_c, \mathbf{x}_c, \mathbf{w}'_c)}_{\text{Vollständiger Modell-Erwartungswert}} \end{aligned} \quad (2.11)$$

Dabei beschreibt:

- Der erste Term den Erwartungswert des Merkmals f_k , wenn die Ausgabe $\mathbf{y}$ auf die Trainingsdaten fixiert ist.

- Der zweite Term den Erwartungswert des Merkmals unter der aktuellen Modellverteilung über alle möglichen $\mathbf{y}$ und $\mathbf{w}$.

Da die Optimierung des Terms durch die Multidimensionalität nicht mehr trivial ist, ist es essenziell vor dem Durchlauf der Optimierung die Parameter korrekt zu initialisieren. [SuttonMcCallum2012]

2.2.9 Stochastische Gradientenverfahren für Online-CRFs

Während klassische Optimierungsverfahren wie L-BFGS [liu1989limited] im Batch-Modus operieren und den gesamten Datensatz scannen müssen, bevor eine Parameteraktualisierung erfolgt, nutzen viele CRFs stochastische Gradientenverfahren. Dies ist besonders effizient, wenn die Trainingsdaten redundant sind oder die Datenmenge zu groß für den Arbeitsspeicher ist.

Bei jedem Iterationsschritt m wird ein einzelnes Trainingsbeispiel $(\mathbf{x}^{(i)}, \mathbf{y}^{(i)})$ zufällig ausgewählt. Die Parameter θ werden anschließend basierend auf dem Gradienten dieser einzelnen Instanz aktualisiert:

$$\theta^{(m)} = \theta^{(m-1)} - \alpha_m \nabla \ell_i(\theta^{(m-1)}) \quad (2.12)$$

Der Gradient für eine einzelne Instanz eines Linear Chain CRF ist dabei definiert als:

$$\frac{\partial \ell_i}{\partial \theta_k} = \sum_{t=1}^T f_k(y_t^{(i)}, y_{t-1}^{(i)}, x_t^{(i)}) - \sum_{t=1}^T \sum_{y, y'} f_k(y, y', x_t^{(i)}) p(y, y' | x^{(i)}) - \frac{\theta_k}{N \sigma^2} \quad (2.13)$$

Ein entscheidender Faktor für die Konvergenz ist die Wahl der Lernrate α_m . Da ein konstanter Wert dazu führen würde, dass die Parameter dauerhaft um das Optimum fluktuieren, wird häufig eine schrittweise Optimierung verwendet, die über die Zeit abnimmt:

$$\alpha_m = \frac{1}{\sigma^2(m_0 + m)} \quad (2.14)$$

Hierbei ist m_0 ein Hyperparameter, der oft durch einen kurzen Testlauf auf einer Teilmenge der Daten bestimmt wird. Online-CRFs bieten einen Geschwindigkeitsvorteil bei großen, unabhängig und identisch verteilten (i.i.d.) Datensätzen, erfordern jedoch im Vergleich zu Batch-Algorithmen eine sorgfältigere Feinabstimmung der Hyperparameter. [SuttonMcCallum2012]

2.2.10 Kontinuierliche Markovprozesse: Kalmanfilter zur Approximation linearer dynamischer Systeme

Für die Darstellung nichtdiskreter Zeit und Zustandsräume wurden komplexere Versionen der Markovprozesse entwickelt. Insbesondere

wenn es sich um eine Bewertung mehrdimensionaler Systeme handelt, reichen einfache diskrete Markovketten oftmals nicht aus.

Speziell wenn eine Linearität der zugrunde liegenden Funktionen sowie eine gaußsche Verteilung der Messfehler angenommen werden kann, bietet sich der Einsatz von Kalmanfiltern an. Diese wurden 1960 von R. E. Kalman vorgestellt [kalman1960new] und sind eine Methode zur Schätzung des Zustands eines dynamischen Systems aus einer Reihe von verrauschten Messungen.

Kalmanfilter können aus einem vorherigen Zustand eine Vorhersage des nächsten Zustands treffen und diese Vorhersage dann mit einer neuen Messung aktualisieren, um eine verbesserte Schätzung zu erhalten. Dies geschieht durch die Anwendung von zwei Hauptschritten: dem Vorhersageschritt und dem Aktualisierungsschritt.

Das zugrunde liegende System wird als lineares dynamisches System modelliert. Der Zustand x_k zum Zeitpunkt k ergibt sich aus dem vorherigen Zustand x_{k-1} , dem Steuerungssignal u_{k-1} und dem Prozessrauschen w_{k-1} :

$$x_k = Ax_{k-1} + Bu_{k-1} + w_{k-1}, \quad w_{k-1} \sim \mathcal{N}(0, Q). \quad (2.15)$$

Die Messung z_k wird durch die Messmatrix H und das Messrauschen v_k beschrieben:

$$z_k = Hx_k + v_k, \quad v_k \sim \mathcal{N}(0, R). \quad (2.16)$$

Durch Konstruktion eines Modells mit diesen Annahmen kann der Kalmanfilter effizient den Zustand des Systems schätzen, indem er die Unsicherheit in den Messungen und im Prozessrauschen berücksichtigt. Die Qualität der Schätzung hängt dabei insbesondere davon ab, ob zu Beginn sinnvolle Kovarianzen Q und R für die jeweiligen Rauschanteile gewählt wurden und ob die Matrix A die Dynamik des Systems gut beschreibt.

Der Kalmanfilter kann auf mehrere Dimensionen erweitert werden, um komplexere Systeme zu modellieren. In diesem Fall werden die Zustandsvektoren, Messvektoren und Rauschkovarianzmatrizen entsprechend angepasst.

2.2.11 Chapman Kolmogorov Gleichung

Die Chapman Kolmogorov Gleichung beschreibt, wie die Übergangswahrscheinlichkeit eines Markovprozesses über mehrere Zeitschritte hinweg berechnet werden kann. Dabei wird ein möglicher Zwischenzustand k zu einem Zeitpunkt m berücksichtigt, sodass die Wahrscheinlichkeit für einen Übergang von Zustand i zu Zustand j nach $n + m$ Schritten über die Gesamtheit aller Zwischenzustände dargestellt werden kann.

Für einen Markovprozess $\{X_t\}_{t \geq 0}$ mit Zustandsraum S gilt für alle $i, j \in S$ und $n, m \geq 0$:

$$P(X_{n+m} = j | X_0 = i) = \sum_{k \in S} P(X_{n+m} = j | X_m = k, X_0 = i) \cdot P(X_m = k | X_0 = i). \quad (2.17)$$

Mit Hilfe der Markoveigenschaft vereinfacht sich der erste Term, da der zukünftige Zustand X_{n+m} nur vom aktuellen Zustand X_m abhängt, nicht aber vom gesamten Verlauf bis $X_0 = i$:

$$P(X_{n+m} = j | X_m = k, X_0 = i) = P(X_{n+m} = j | X_m = k). \quad (2.18)$$

Damit ergibt sich die Chapman Kolmogorov Gleichung in der üblichen Form:

$$P(X_{n+m} = j | X_0 = i) = \sum_{k \in S} P(X_{n+m} = j | X_m = k) \cdot P(X_m = k | X_0 = i). \quad (2.19)$$

Schreibt man die Übergangswahrscheinlichkeiten in Matrixform, so entspricht dies der Aussage:

$$P^{(n+m)} = P^{(m)} \cdot P^{(n)}, \quad (2.20)$$

wobei $P^{(r)}$ die r Schritt Übergangsmatrix bezeichnet.

Über eine solche Übergangsmatrix können Vorhersagen über zukünftige Zustände eines Markovprozesses getroffen werden, indem die Matrix potenziert wird. Das bedeutet, dass die n Schritt Übergangsmatrix $P^{(n)}$ durch die n fache Multiplikation der Einschrittübergangsmatrix P mit sich selbst berechnet werden kann:

$$P^{(n)} = \underbrace{P \cdot P \cdot \dots \cdot P}_{n \text{ Mal}} = P^n. \quad (2.21)$$

2.2.12 Viterbidekodierung

Der Viterbialgorithmus ist ein dynamischer Programmialgorithmus, der verwendet wird, um die wahrscheinlichste Sequenz von versteckten Zuständen in einem verdeckten Markovmodell zu finden, basierend auf einer gegebenen Sequenz von beobachteten Ereignissen. Der Algorithmus wurde von Andrew Viterbi 1967 [**viterbierror**] erstmals vorgeschlagen und ist besonders nützlich in Anwendungen, bei denen sequenzielle Daten auftreten, deren Zusammensetzung Schlüsse auf die zugrundeliegenden wahren Zustände zulassen. Die Fähigkeit, aus den beobachtbaren Zuständen auf versteckte Wahrheiten schließen zu können, macht den Viterbialgorithmus praxisrelevant in vielen Bereichen, etwa in der Elektrotechnik bei der Analyse von Kommunikationssystemen oder in der Bioinformatik bei der Genomsequenzierung. Hierbei werden Emissionswahrscheinlichkeiten sowie Übergangswahrscheinlichkeiten zwischen den Zuständen berücksichtigt, um die wahrscheinlichste Sequenz zu bestimmen.

Notation: Seien $i, j \in \{1, \dots, N\}$ die Zustände und $o_1, \dots, o_T$ die Beobachtungssequenz. Die Übergangswahrscheinlichkeiten sind $a_{ij} = P(s_t = j \mid s_{t-1} = i)$, die Emissionswahrscheinlichkeiten $b_j(o_t) = P(o_t \mid s_t = j)$ und die Anfangsverteilung $\pi_i = P(s_1 = i)$. Dabei bezeichnet $\delta_t(j)$ die maximale Pfadwahrscheinlichkeit bis zum Zeitpunkt t , die im Zustand j endet, und $\psi_t(j)$ den optimalen Vorgängerzustand.

INITIALISIERUNG

$$\delta_1(i) = \pi_i \cdot b_i(o_1), \quad \text{für } i = 1, \dots, N, \quad (2.22)$$

$$\psi_1(i) = 0, \quad \text{für } i = 1, \dots, N. \quad (2.23)$$

REKURSION Für $t = 2, \dots, T$ und $j = 1, \dots, N$:

$$\delta_t(j) = \left[\max_{i \in \{1, \dots, N\}} \delta_{t-1}(i) \cdot a_{ij} \right] \cdot b_j(o_t), \quad (2.24)$$

$$\psi_t(j) = \arg \max_{i \in \{1, \dots, N\}} \delta_{t-1}(i) \cdot a_{ij}. \quad (2.25)$$

TERMINIERUNG

$$P^* = \max_{i \in \{1, \dots, N\}} \delta_T(i), \quad (2.26)$$

$$s_T^* = \arg \max_{i \in \{1, \dots, N\}} \delta_T(i). \quad (2.27)$$

RÜCKVERFOLGUNG Für $t = T - 1, T - 2, \dots, 1$:

$$s_t^* = \psi_{t+1}(s_{t+1}^*). \quad (2.28)$$

LOGARITHMIERT (NUMERISCH STABIL) Um numerische Unterläufe zu vermeiden, kann der Algorithmus im Logarithmusbereich durchgeführt werden. Definiere $\ell_t(j) = \log \delta_t(j)$. Dann gilt:

Initialisierung:

$$\ell_1(i) = \log \pi_i + \log b_i(o_1), \quad \text{für } i = 1, \dots, N. \quad (2.29)$$

Rekursion (Logbereich): Für $t = 2, \dots, T$ und Zustand j :

$$\ell_t(j) = \max_i [\ell_{t-1}(i) + \log a_{ij}] + \log b_j(o_t), \quad (2.30)$$

$$\psi_t(j) = \arg \max_i [\ell_{t-1}(i) + \log a_{ij}].$$

Hierbei ist a_{ij} die Übergangswahrscheinlichkeit und $b_j(o_t)$ die Emissionswahrscheinlichkeit, dass Frame o_t im Zustand j beobachtet wird.

Terminierung:

$$P^* = \max_{i \in \{1, \dots, N\}} \ell_T(i), \quad (2.31)$$

$$s_T^* = \arg \max_{i \in \{1, \dots, N\}} \ell_T(i).$$

Rückverfolgung:

$$s_t^* = \psi_{t+1}(s_{t+1}^*), \quad \text{für } t = T - 1, T - 2, \dots, 1. \quad (2.32)$$

Durch den Einsatz des Viterbialgorithmus im logarithmischen Bereich kann also effizient die wahrscheinlichste Abfolge von Zuständen eines Systems ermittelt werden.

2.2.13 *Dynamik von Zustandsfolgen: Potenzgesetze und Kaskaden in Markov-Systemen*

Bei der Modellierung klinischer Sequenzen tritt ein Phänomen auf, das über die einfache Betrachtung stationärer Verteilungen hinausgeht. Während klassische Markov-Ketten oft auf ein langfristiges Gleichgewicht (stationäre Verteilung) zusteuern, zeigen reale Prozesse häufig divergente Eigenschaften oder extrem ungleich verteilte Verweildauern in einzelnen Zuständen.

Ein theoretischer Erklärungsansatz hierfür sind Potenzgesetze. Wie in der Literatur dargelegt, lassen sich diese direkt aus speziellen Markov-Ketten herleiten, indem man eine Mastergleichung für sogenannte Kaskaden aufstellt [10.1098/rsos.220531]. Unter einer Kaskade versteht man hierbei eine Folge aufeinanderfolgender identischer Übergänge, die erst enden, wenn ein Zustandswechsel eintritt.

Diese mathematische Betrachtung ist für die Endoskopie aus zwei Gründen von zentraler Bedeutung: Varianz Innerhalb eines Endoskopievideos gibt es keine statischen Gleichgewichte. Ein System kann minutenlang im Zustand „Innen“ verweilen (eine lange Kaskade), bevor ein abrupter Wechsel zu „Außen“ erfolgt. Die Verteilung dieser Kaskadenlängen folgt oft einem Potenzgesetz mit einem natürlichen Cut-off, der durch die endliche Dauer des klinischen Eingriffs limitiert wird. Ein rein auf Übergangswahrscheinlichkeiten basierendes Modell läuft Gefahr, in stabilen Zuständen zu „verharren“, wenn die statistische Wahrscheinlichkeit für einen Wechsel (z. B. nach einer langen Sequenz von Innen-Frames) mathematisch unterschätzt wird. In realen Systemen werden stationäre Verteilungen oft durch externe Einflüsse oder die Kopplung an andere Zustandsgrößen gestört. Dies erschwert die Vorhersage langfristiger Zustände allein aus der Historie der Übergänge. Für die vorliegende Arbeit bedeutet dies: Um eine robuste Segmentierung zu gewährleisten, darf der Algorithmus nicht allein auf der zeitlichen Stabilität der Markov-Kette beruhen. Es ist essenziell, die Zustandsänderungen an externe Faktoren, in diesem Fall die visuellen Merkmale wie Farbwerte und Texturen der Videoframes – zu koppeln. Nur so kann sichergestellt werden, dass das Modell auch nach einer langen Kaskade (etwa wenn das Endoskop während einer Unterbrechung unbewegt bleibt) sofort auf neue visuelle Informationen reagiert und den Zustand korrekt anpasst.

Die Motivation zu dieser Abschlussarbeit stammt aus der Publikation von Lux et. al. [lux-2023], in der ein framebasierter Ansatz zur Segmentierung von Endoskopievideos vorgestellt wird. Hier wird diskutiert, welche Herausforderungen im klinischen Einsatz von Frame by Frame Segmentation von Endoskopievideos auftreten können. Lux et. al. schlagen vor, assistierte Dokumentation als Ziel der Segmentierung von Endoskopien zu definieren. Das Ziel ist es also die benötigte Zeit für die Dokumentation sowie die Auswertung von Videodaten zu reduzieren. Dieser Fokus weicht ab von der Zielsetzung vieler anderer Publikationen, die sich auf Empfehlungen der European Society of Gastrointestinal Endoscopy (ESGE) sowie der American Society for Gastrointestinal Endoscopy (ASGE) berufen, laut denen eine Erhöhung der Adenomdetektionsrate ein wichtiges Ziel bei der Qualitätssicherung von Endoskopien ist. [Rex_2022][kaminski-performance-2017] In mehreren randomisierten Studien konnten Systeme zur Detektion von Adenomen erfolgreich getestet werden. Spadiaccini et al geben beispielsweise eine Steigerung der ADR von 5,6% in Kombination mit einem System zur Detektion von Mukosaexposition an. [SPADACCINI2023244] Budzyn et al fanden durch eine Analyse des Einsatzes von Systemen zur klinischen Adenomdetektionsrate hingegen eine Reduktion der ADR vor. [budzyn2025deskilling] Auch Hann et al wiesen darauf hin, dass der Einsatz der KI basierten Systeme während der Untersuchung zur Polypendetektion auch zu einem Sinken oder zu gleichbleibender Adenomdetektionsrate führen kann. [hann_entscheidungsunterstützung_2025] Der pure Fokus der Analyse von Endoskopievideos auf die Entscheidungsunterstützung scheint hierbei nicht zwangsweise zu besseren Ergebnissen zu führen, ein Umstand der laut Hann et al eng mit dem Verlust von Aufmerksamkeit durch das Vertrauen in Prädiktionssysteme zusammenhängen könnte. Sie wiesen zudem darauf hin, dass die Boxen zur Erkennung von Polypen im klinischen Rahmen ablenkend bei der Resektion sein können, ein weiterer Umstand der adressiert werden sollte. Rafner et al riefen in Ihrem Essay zu Deskilling, dem Verlust von Kompetenzen durch Automatisierung, generell dazu auf, den Einsatz von hybrider Intelligenz zu verfolgen um nicht durch Verlust menschlicher Kompetenz schlechtere Ergebnisse zu erreichen. [rafner_2025_deskilling] Aus diesem Standpunkt heraus macht es also Sinn, die Analyse von klinischen Untersuchungen parallel zur Analyse von medizinischen Fachpersonal für einen Abgleich am Ende zu nutzen. Potenziell sehen einer Umfrage zufolge viele Gastroenterologen den Einsatz der KI zudem zum Zwecke der Zusammenfassung

und Segmentierung positiv und weitere Forschung in diesem Bereich ist erwünscht. [**munzer_content-based-2018**] Savides et. al. analysierten zum Beispiel, dass die Triage interventionaler GI-Überweisungen derzeit in amerikanischen Kliniken mit erheblichem Zeitaufwand verbunden ist. [**savides2025triaging**] Neben sowie während der Triage ist auch die Dokumentation ein erheblicher Zeitfaktor. In Zukunft könnte dieser Aufwand deutlich reduziert werden, wenn KI-basierte Systeme zur automatisierten Bild- oder Frame-Analyse (z.B. aus endoskopischen Videos) zur Unterstützung der Triagierung eingesetzt werden.

Lux et. al. beschreiben ein Verfahren zur automatisierten Dokumentation von Endoskopievideos. [**lux-2023**] Dabei wird ein auf Deep Learning basierendes System eingesetzt, um relevante Informationen aus den Videos zu extrahieren und in strukturierter Form bereitzustellen. Diese Form ist hierbei eine Liste von Labels, die die zeitlichen Regionen des Videos beschreiben. Das System nutzt Convolutional Neural Networks (CNNs), um verschiedene Merkmale in den Endoskopiebildern zu erkennen, wie z.B. Polypen, Läsionen oder anatomische Strukturen. Die Autoren zeigen, dass das System eine gute Genauigkeit bei der Erkennung relevanter Merkmale aufweist und somit bereits die Effizienz und Qualität der Endoskopiedokumentation verbessern kann. Probleme bestehen

Das Ziel der Segmentierung in dieser Arbeit ist es, eine Methode zur assistierten Dokumentation zu präsentieren, die Labels mit dazugehörigen Frames verknüpft und somit eine strukturierte Übersicht über das Videomaterial bietet. Dies ist besonders relevant für die Nachbereitung von langen Videodateien, wie Endoskopien. So kann bei der Analyse so schneller auf wichtige Informationen zugreifen können. Viele Autoren betonen, dass eine solche assistierte Dokumentation nicht nur die Effizienz steigert, sondern auch die Genauigkeit der Berichte verbessert, indem menschliche Fehler ausgeglichen werden. Die weitere Entwicklung der assistierten Dokumentation wird als neuer Fokus vorgeschlagen. Diese Empfehlung deckt sich weitestgehend mit der einer weiteren Zielsetzung der aus [**kaminski-performance-2017**], die in ihrer Publikation Forschungsfragen zur Verbesserung der Qualitätssicherung bei der Bewertung der Vollständigkeit von Darmspiegelungen durch Dokumentation aufstellen. Hierbei kann also als Optimierung angenommen werden, dass sich diese vor entweder durch Verbesserung von korrekter Segmentierung der Frames eines Videos oder durch eine Beschleunigung der Verarbeitung und das Nutzbar machen der automatisierten Dokumentation durch Beschleunigung erreichen lässt. Aus diesem Grund möchte ich mich in dieser Arbeit dem von Lux et al genannten Fokus auf assistierte Dokumentation anschließen und eine zeiteffiziente Methode zur Kombination verschiedener Auswertungsquellen zu einem System zur Unterstützung der Frameauswahl und Segmentierung basierend auf HMMs präsentieren.

In diesem Abschnitt sollen die verschiedenen Methoden die bisher speziell im Bereich der Endoskopie häufig zum Einsatz kommen Erwähnung finden und später im Rahmen der von Lux et al. geforderten praxisrelevanten assistierten Dokumentation zu einem zusammenhängenden System kombiniert werden.

3.0.1 *Kombination verschiedener Features wie Farbraumanalyse oder Bewegungserkennung in einem HMM*

Die Klassifikation von Kapselendoskopien mittels Farbanalyse wurde bereits erfolgreich erprobt und zeigt gute Ergebnisse. In der Publikation von Mackiewicz et al. konnte durch die Verwendung von Farbraumklasifizierung und eines HMM gute Ergebnisse bei der automatischen Erkennung der aktuellen Position der endoskopischen Kapsel innerhalb des Körpers gezeigt werden. Um das Rauschen einzelner Features zu kompensieren nutzten die Autoren hierbei eine Kombination aus der Likelihood und Die Autoren der Publikation konstruierten ein HMM, das die Position der Kapsel innerhalb der Endoskopie mit Hilfe einer durch mehrere Trainingsdurchläufe erarbeiteten Übergangsmatrix beschrieb. Zur Klassifikation von Die Autoren hoben hierbei hervor, dass die Erkennung der Unterschiede der verschiedenen Organe im Körper während des Durchlaufs der Kapseldoskopie (z.b Übergang von Magen zum Dünndarm zum Dickdarm) den in der Publikation betrachteten Systemen größere Probleme bereitete als die Erkennung des Übergangs vom Inneren des Körpers zu den Regionen außerhalb. Hier war das sinnvollste System die Kombination eines SVM und des HMM. Dieses Ergebnis wird in der Arbeit berücksichtigt, indem die Segmentierung der Frames in grobe räumliche Kategorien innerhalb des Darms mit einem durch Kalmanfilter ergänzten HMM erprobt wird. [4530644]

3.1 COMPUTER VISION - VERARBEITUNG VON BILDDATEN

Der visuelle Kortex des Menschen ist dafür ausgelegt, die Intensitätswerte von Wellenlängen des Lichts, das auf die einzelnen Zellen der Netzhaut fällt, auszuwerten. Auch Computer nutzen die Farbwerte von Pixeln sowie deren Intensität um Bilder zu analysieren. Die Menge der Pixel in einem Bild sowie die Farbtiefe bestimmen hierbei die Informationsdichte eines Bildes. So kann ein Bild mit einer Auflösung von 1920x1080 Pixeln und einer Farbtiefe von 24 Bit (8 Bit pro Farbkanal Rot, Grün, Blau) insgesamt 16.777.216 Farben darstellen. Jedes Pixel in diesem Bild wird durch drei Werte repräsentiert, die die Intensität der jeweiligen Farbkanäle angeben. Die Verarbeitung und Analyse dieser Bilddaten erfordert spezialisierte Algorithmen und Modelle, die in der Lage sind, Muster, Formen und Strukturen innerhalb der Bilder zu erkennen und zu interpretieren. In der medizinischen Bildverarbeitung, wie z.B. bei der Analyse von Endoskopiebildern, spielen diese Techni-

ken eine entscheidende Rolle bei der Diagnose und Behandlung von Krankheiten. Im folgenden werden einige der wichtigsten aktuellen Methoden und Modelle vorgestellt, die in der Computer Vision zur Verarbeitung von Bilddaten eingesetzt werden.

3.2 CNN - KONVOLUTIONSKERNELS ZUR ANALYSE VON BILDDATEN.

Lux et al [lux-2023] stellten in ihrer Publikation eine Lösung zur Segmentierung von verschiedenen Bereichen eines Videos vor. Die Autoren verwenden hier ein CNN um einzelne Frames verschiedenen Segmentierungskategorien zuzuordnen. Die Klassifikation von Videos und Bildern aus der Endoskopie mit ResNet, einem residuellen neuronalen Netz, sowie mit anderen CNN wird als Methode in vielen Publikationen beschrieben und zeigt generell gute Ergebnisse. [9360830] Konvolutionale neuronale Netze (CNN) [6795724] sind eine spezielle Klasse künstlicher neuronaler Netze, die insbesondere für die Verarbeitung von Bilddaten entwickelt wurden. Das zentrale Element eines CNN ist die Faltungsschicht, in der sogenannte Filter (oder Konvolutionskerne) die Pixel des Eingabebilds in lokale Merkmale übersetzen. Dabei gleiten Konvolutionskerne über das Bild. Mathematisch basiert diese Operation auf der Faltung (engl.), bei der die Werte eines kleinen Bereichs des Bildes mit den Werten des Filters multipliziert und aufsummiert werden. Dadurch entstehen durch Deep Learning gelernte Featurekombinationen, die charakteristische Muster wie Kanten, Ecken oder komplexere Strukturen erkennen können.

Durch die hierarchische Anordnung mehrerer Faltungs- und Pooling-Schichten können CNNs zunehmend abstrakte Merkmale aus den Rohdaten extrahieren. Dies ermöglicht es, Bildinhalte effizient zu analysieren und zu klassifizieren. Die Parameter der Filter werden während des Trainingsprozesses durch Backpropagation optimiert, sodass das Netzwerk lernt, relevante Merkmale für die jeweilige Aufgabe zu erkennen.

Um die Qualität der Klassifikation von Bildern bei komputational vertretbarem Rechenaufwand zu verbessern, konnte mit dem Inception-Next ein neuer vielversprechender Ansatz gefunden werden. [yu2024inceptionnext] Yu et. al. nutzen in Ihrer Publikation kleinere Konvolutionskernels um die Rechenzeit zu reduzieren. Netzwerke wie EfficientNet sind für den mobilen Gebrauch optimiert und können in Echtzeitanalysen eingesetzt werden, eine Eigenschaft die nun dafür genutzt werden kann, die Anwendungen in Echtzeit auszuführen. [Tan2019EfficientNetRM] Die generelle Verbesserung der Effizienz von CNNs ist ein wichtiger Schritt, um deren Einsatz in ressourcenbeschränkten Umgebungen zu ermöglichen, wie z.B. bei der Analyse von Endoskopievideos in Echtzeit während klinischer Untersuchungen.

Generell lässt sich festhalten dass konvolutionale neuronale Netze zum standardmäßigen Verfahren für die Analyse von Bilddaten gehören und in vielen Bereichen der medizinischen Bildverarbeitung erfolgreich

eingesetzt werden. Ihre Fähigkeit, komplexe Muster in Bildern zu erkennen und zu klassifizieren, macht sie zu einem unverzichtbaren Werkzeug in der modernen Computer Vision und sie erreichen im Schnitt eine bessere Genauigkeit bei der Bildklassifikation als andere Verfahren wie SVMs oder Entscheidungsbäume. [Voulodimos2018DeepLF]

3.2.1 Vision Transformer - Nutzung von Attentionmechanismen für die Bildklassifikation

Seitdem die Transformer-Architektur [NIPS2017_3f5ee243] den Attention-Mechanismus als zentrales Element für die natürliche Sprachverarbeitung (NLP) einführte, gab es im Bereich der großen Sprachmodelle massive Fortschritte. Der Kern dieser Architektur ist der Self-Attention-Mechanismus, der es dem Modell ermöglicht, Abhängigkeiten zwischen Wörtern unabhängig von ihrer Distanz im Satz zu lernen. Mathematisch wird die skalierte Attention mit dem Skalarprodukt wie folgt definiert:

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V \quad (3.1)$$

Hierbei stehen Q (Query), K (Key) und V (Value) für die Eingabektoren und d_k für die Dimension der Keys, was zur Skalierung dient, um verschwindende Gradienten zu vermeiden.

3.2.1.1 Übertragung auf die Bildverarbeitung

Der Durchbruch in der Bildverarbeitung gelang Dosovitskiy et al. mit dem Vision Transformer (ViT) [dosovitskiy2020image]. Da Bilder keine sequentielle Wortstruktur besitzen, wird das Eingabebild $x \in \mathbb{R}^{H \times W \times C}$ in eine Sequenz von flachen 2D-Patches $x_p \in \mathbb{R}^{N \times (P^2 \cdot C)}$ zerlegt. Diese Patches werden analog zu Wörtern im NLP als Token behandelt, linear projiziert und mit einer Positionskodierung versehen, um die räumliche Information zu erhalten.

Im Gegensatz zu CNNs, die durch die begrenzte Größe der Faltungskerne primär lokale Merkmale wie Kanten und Texturen erfassen, ermöglicht der Self-Attention-Mechanismus des ViT das Modellieren globaler Zusammenhänge über das gesamte Bild hinweg.

3.2.1.2 Anwendung in der Endoskopiesegmentierung

In der Endoskopie ist dieser globale Kontext entscheidend, da Läsionen wie Polypen oft schwer vom umliegenden Gewebe zu unterscheiden sind (Camouflage-Effekt) oder in Größe und Form stark variieren. Reine CNNs verlieren bei tiefen Netzwerken oft räumliche Details oder scheitern an komplexen globalen Strukturen.

Um die Stärken beider Welten zu kombinieren, etablierten sich hybride Architekturen als State-of-the-Art:

- TransUNet [**chen2021transunet**] kombiniert einen CNN-Encoder für die Extraktion lokaler Features mit einem Transformer-Modul für den globalen Kontext. Dies gilt als wegweisende Arbeit für die medizinische Segmentierung, da es die Detailgenauigkeit von U-Net mit der Kontextsensitivität von Transformern vereint.
- Polyp-PVT [**dong2021polyppvt**] nutzt einen Pyramid Vision Transformer (PVT), um die typischen quadratischen Rechenkosten von Standard-ViTs zu reduzieren und gleichzeitig feine Strukturen von Polypen besser vom Hintergrund zu trennen. Durch spezialisierte Module adressiert dieses Modell spezifisch das Problem der unscharfen Grenzen bei Polypen.

Aktuelle Benchmarks zeigen, dass diese Transformer-basierten Ansätze insbesondere bei schwierigen Segmentierungsaufgaben, wie der Erkennung kleiner oder getarnter Polypen, den klassischen CNN-Architekturen überlegen sind [**wang2022stepwise**].

Generell lässt sich also festhalten, dass bei der Detektion von Polypen durch die große Menge der Trainingsdaten sowie Fortschritte der Modelle der Bildverarbeitung gemacht wurden. Aus diesem Grund legt diese Arbeit den Fokus auf die Vorverarbeitung des Videos.

Wie in den vorangegangenen Kapiteln dargelegt, besteht ein valides Interesse daran, die Durchführung und Dokumentation von Endoskopien durch den Einsatz von künstlicher Intelligenz und Informationssystemen effizienter zu gestalten. Dabei ist es jedoch, wie Hann et al. [hann_entscheidungsunterstützung_2025] betonen, essenziell zu evaluieren, an welchen Stellen sich erweiterte Methoden tatsächlich positiv auf den Arbeitsaufwand auswirken. Die Akzeptanz im klinischen Alltag hängt, neben der diagnostischen Genauigkeit maßgeblich von der rechnerischen Effizienz sowie der Verlässlichkeit der Vorhersagen ab. [Ali2020] Außerdem sollte laut Rafner et. al. evaluiert werden, ob es zu deskilling durch das vollständige Ersetzen der Tätigkeiten der handelnden Personen kommen kann. [rafner_2025_deskilling]

Um eine automatisiert assistierte Dokumentation zu integrieren, muss die Verarbeitung der Videodaten unter geringer Latenz und mit moderatem Ressourcenverbrauch erfolgen. Das Ziel ist daher die Entwicklung effizienter Algorithmen, die eine schnelle Segmentierung von Videoframes in semantische Kategorien ermöglichen. Eine valide Segmentierung bildet die Grundlage für nachgelagerte Prozesse, wie die automatisierte Erstellung von Befundberichten, statistische Auswertungen der Untersuchungsqualität sowie die gezielte Anonymisierung patientenbezogener Daten.

Um eine robuste Segmentierung zu gewährleisten, muss das Verfahren sowohl lokale Bildinformationen (Textur, Farbe) als auch den globalen zeitlichen Kontext der Videoaufnahme berücksichtigen. Das Ziel dieser Arbeit ist die Entwicklung eines Systems, das diese Anforderungen erfüllt, ohne dabei eine Komplexität zu erreichen, die einer praxisrelevanten Nutzung (z. B. auf Studienlaptops neben dem Endoskopieturm oder kleinen Rechnern) entgegensteht. Aus diesem Grund implementiert das System den Ansatz der temporalen Partitionierung direkt in der Modellarchitektur. Die Intuition hierbei ist folgende: Wenn das Ziel die Bewertung des Videos in diskreten Segmenten ist, sollten auch die Entscheidungskriterien (Features) nicht global uniform, sondern segmentspezifisch und zustandsabhängig evaluiert werden.

Hierfür wird die folgende Hypothese aufgestellt:

Durch den Einsatz eines HMMs oder CRF zur Vorverarbeitung des Videostroms kann die Anzahl der Frames, auf denen der Einsatz rechenintensiver Deep-Learning-Modelle (wie CNN oder ViT) notwendig ist, signifikant reduziert werden. Es soll erprobt werden, ob irrelevante Zustände sowie Regionen von erhöhtem Interesse unter Zuhilfenahme diskriminativer (CRF) oder gene-

rativer Modelle schneller und zuverlässiger identifiziert werden können als durch die alleinige Anwendung eines CNNs.

4.1 KONZEPTIONELLES MODELL ZUR ZUSTANDSABSCHÄTZUNG

Die Analyse endoskopischer Videos stellt eine besondere Herausforderung dar, da die Bildfolgen sowohl kontinuierliche visuelle Dynamiken (Beleuchtung, Bewegung, Farbspektrum) als auch diskrete prozedurale Phasen aufweisen. Ein rein kontinuierliches Modell erfasst die abrupten Übergänge zwischen diesen Phasen oft nur unzureichend, während ein rein diskretes Modell das innerhalb einer Phase auftretende Messrauschen und graduelle Veränderungen vernachlässigt.

Aus diesem Grund wird ein hybrides probabilistisches Modell vorgeschlagen, das diskrete Zustandsdynamiken und kontinuierliche Merkmalsextraktion in einem gemeinsamen formalen Rahmen kombiniert und die Stärken der sequenziellen markovbasierten Modelle bei der Sequenzierung und Recheneffizienz mit den Stärken neuronaler Netze bei der Erkennung von Texturmerkmalen kombiniert.

Grundidee. Das System basiert auf einer hierarchischen Struktur. Eine Markov-Kette fungiert als übergeordneter Prozess, der die semantischen Phasen des Videos beschreibt (S_t), während lokale Beobachtungsmodelle (basierend auf Feature-Statistiken oder Kalman-Filtern) die Wahrscheinlichkeiten aus den visuellen Messgrößen (y_t) schätzen. Die rekursive Berechnung der Zustandswahrscheinlichkeit folgt der Forward-Rekursion des Hidden-Markov-Modells nach Rabiner [18626], bei der die a-priori Verteilung des vorherigen Zustands über die Übergangsmatrix propagiert und mit der Emissionswahrscheinlichkeit des aktuellen Beobachtungsvektors kombiniert wird. Es sei S_t die diskrete Zufallsvariable zum Zeitpunkt t , die den aktuellen Zustand s_i aus einem Zustandsraum $\{1, \dots, K\}$ annimmt:

$$S_t = s_i \quad (4.1)$$

Die Wahrscheinlichkeit für das Vorliegen eines Zustands ergibt sich unter Anwendung des Satzes der totalen Wahrscheinlichkeit und der Markov-Annahme erster Ordnung:

$$P(S_t = s_i | y_t) \propto P(y_t | S_t = s_i) \sum_{j=1}^K P(S_t = s_i | S_{t-1} = s_j) P(S_{t-1} = s_j) \quad (4.2)$$

Innerhalb einer diskreten Phase s_i werden die Messwerte $y_t \in \mathbb{R}^m$ (z. B. Farbe, Textur, einfache Bewegungsmaße) als skalare Featuregrößen erfasst. In der vorliegenden Implementierung werden die Beobachtungswahrscheinlichkeiten nicht durch eine parametrisierte Dichte gelernt, sondern deterministisch aus statistischen Featureregeln berechnet, die aus Trainingsdaten abgeleitet wurden. Ein diskriminatives Modell (CRF) kann diese Emissionswahrscheinlichkeiten als Eingabe

nutzen und die Zustandsdynamik direkt über $P(S_t | y_t, S_{t-1})$ modellieren.




Abbildung 4.1: Visualisierung der statistischen Entscheidungsregeln, die in der Generation der Featureregeln genutzt werden definieren.

Die in Abbildung 4.1 gezeigten statistischen Regeln bilden die direkte Berechnungsgrundlage für die Beobachtungswahrscheinlichkeiten.

Das System implementiert hierbei eine klare Trennung zwischen Entscheidung (Inferenz) und Adaption (Lernen):

1. **Regelbasierte Likelihood:** Die statischen Regeln (aus `color_feature_states.json`) fungieren als festes Expertenwissen. Für jeden Frame t wird geprüft, ob die extrahierten skalaren Merkmale (z. B. Farbsättigung) die konfigurierten Schwellenwerte (typischerweise One-Sided *greater-than/less-than*, optional Between-Range) erfüllen. Diese Auswertung wird deterministisch in den Likelihood-Vektor $P(y_t | S_t)$ übersetzt, welcher in den Klassifikationsmodellen als Entscheidungsgrundlage genutzt werden.

Somit basiert die Klassifikationsentscheidung in dieser Arbeit vollständig auf den robusten, statistisch hergeleiteten Featureregeln, während individuell während der Erstellung eines Prototypen eine latente Erweiterung zur Laufzeitanalyse existiert.

Beziehung zu bestehenden Arbeiten. Das Grundprinzip weist eine formale Dualität zu dem Ansatz von Odhner et.al. [odhner2010kalman] auf. Während Odhner et al. eine Markov-Kette als zugrundeliegendes System betrachteten und einen Kalman-Filter zur Schätzung der Populationsverteilung nutzten, kehrt die vorliegende Arbeit diese Struktur um: Hier dienen statistische Filter als lokale Schätzer für die Featuredynamik, während die Markov-Kette (oder das CRF) die diskrete Steuerungsebene bildet, welche die Phasenwechsel des endoskopischen Prozesses modelliert. Dies erlaubt die Kombination von lokaler Rauschunterdrückung und globaler Prozesslogik.

Kopplung der Schichten. Die Kopplung erfolgt über die Emissionswahrscheinlichkeiten (im HMM) bzw. die Featurefunktionen (im CRF). Ein hoher Innovationswert (Abweichung der Messung vom erwarteten Zustand) senkt die Wahrscheinlichkeit für das Verbleiben im aktuellen

Zustand und löst über die Übergangsmatrix A_{ij} einen Phasenwechsel aus. Das System „lernt“ somit datengetrieben, wann das aktuell aktive Modell (z. B. für saubere Mukosa) nicht mehr zur beobachteten Dynamik (z. B. Blutung) passt.

Globaler Kontext und Regularisierung. Über die gesamte Videolänge hinweg entsteht so eine Markov-Kette, bei der die einzelnen Zustände durch verschiedene Modelle über Featurevektoren aktualisiert werden. Hierbei wurden verschiedene Features erprobt, die auf im Voraus bekannte oder gelernte Merkmale angepasst werden können. Nach der Markovannahme lassen sich die Annahmen aus den vorherigen Durchläufen, also die Priors, im Prior des aktuellen Zustands zusammenfassen. Die Prior-Aktualisierung erfolgt analog zur zuvor beschriebenen Forward-Rekursion. Da bei Endoskopievideos stellenweise vorhersehbarer, zeitlicher Zusammenhang zwischen den Zuständen vorliegen kann, wird die Sequenzmodellierung in der vorliegenden Implementierung über eine lineare Kette realisiert. Für das HMM entspricht dies der Markov-Faktorisierung:

$$P(s_{1:T}) = \prod_{t=1}^T P(s_t | s_{t-1}).$$

Für das CRF wird hingegen die bedingte Verteilung modelliert,

$$P(s_{1:T} | O) = \frac{1}{Z(O)} \exp \left(\sum_{t=1}^T \sum_k \lambda_k f_k(s_{t-1}, s_t, O, t) \right),$$

wobei die Beobachtungen O in der Implementierung über regelbasierte Emissionswahrscheinlichkeiten eingehen.

Anwendung auf endoskopische Videos. Für die konkrete Anwendung werden die Zustände der Markov-Kette semantisch interpretiert, etwa als *Außerhalb des Körpers*, *NBI-Modus*, *Nahaufnahme der Mukosa*, *Polyp*, *Instrument*, *Blut* oder *Niedrige Bildqualität*. Jeder dieser Zustände müsste eine spezifische Dynamik visueller Merkmale besitzen, um durch ein geeignetes Modell beschrieben werden zu können. Diese Parameter können durch Domänenwissen vorinitialisiert werden – etwa durch die erwartete Kamerabewegung oder typische Helligkeitsschwankungen in einem bestimmten Abschnitt – oder datengetrieben verfeinert werden. In der Implementierung werden die Beobachtungsinformationen nicht als frei trainierbare Feature-Funktionen gelernt, sondern als Emissionswahrscheinlichkeiten aus den regelbasierten Likelihoods berechnet und den Modellen als Eingabe übergeben. Optional werden die Übergangsgewichte während des Trainings mit sequenziellen gelabelten Frames aktualisiert.

4.1.1 Statistische Herleitung der Featureregeln

Um robuste Entscheidungsgrenzen für die Regeln zu finden, wird ein datengetriebener Ansatz gewählt, der auf der Analyse der Feature-

Verteilungen (Mittelwert μ_c , Standardabweichung σ_c) pro Klasse c basiert. Die Berechnung dieser Momente erfolgt aus den Messungen der Werte für die Labels.

Basierend auf diesen Statistiken werden Featureregeln $\mathcal{R}$ definiert, die als deterministische Prüffunktionen in die Emissionsberechnung eingehen. Eine Regel $r \in \mathcal{R}$ für ein Feature x (z. B. Farbsättigung oder LBP-Komplexität) und einen Zustand s ist definiert als:

$$f_r(s_t, y_t) = \mathbb{1}_{\{s_t=s\}} \cdot w_r \cdot \text{sat}_r(y_t) \quad (4.3)$$

Die Erfüllungsfunktion $\text{sat}_r(y_t)$ prüft, ob der Messwert innerhalb eines statistisch signifikanten Intervalls liegt. Hierbei unterscheiden wir zwei Typen von Regeln, die die Topologie des Feature-Raums abbilden:

1. **Diskriminative Grenzwerte:** Wenn der Mittelwert einer Klasse signifikant (definiert durch ein relatives δ) vom globalen Mittelwert abweicht, wird eine harte Grenze gesetzt.

$$\text{sat}_{\text{gt}}(y) = \begin{cases} 1 & \text{wenn } y > \mu_s - 0.5\sigma_s \\ 0 & \text{sonst} \end{cases}$$

Dies wird typischerweise für auffällige Merkmale wie *hohe Rötung* (Blutung) oder *hohe Texturkomplexität* (Artefakte) verwendet.

2. **Topologische Akzeptanzbereiche:** Für Zustände, die durch einen spezifischen Wertebereich charakterisiert sind (z. B. Stuhl mit mittlerer Sättigung), wird ein Toleranzintervall definiert:

$$\text{sat}_{\text{btwn}}(y) = \begin{cases} 1 & \text{wenn } \mu_s - 2\sigma_s \leq y \leq \mu_s + 2\sigma_s \\ 0 & \text{sonst} \end{cases}$$

Die Gewichtung w_r ist in den Zustandsdefinitionen fixiert. Das CRF-Training aktualisiert ausschließlich die Übergangsgewichte, nicht jedoch die Regeln selbst, da diese bereits während der Kalibrierung entschieden wurden.

Diese Regeln werden in einer .json datei gespeichert. Dabei werden Features aus Bildern extrahiert (HSV, CIELAB- und LBP-Merkmale). Für jedes Label sowie global werden Mittelwert, Standardabweichung und Quantile fortlaufend mit den numerisch stabilen Algorithmus nach Welford [**welford1962note**] berechnet. Die Signifikanz eines Features wird als Abweichung vom globalen Mittelwert definiert: Bei sehr kleinem globalen Mittel wird eine absolute Abweichung (`abs_delta`), ansonsten eine relative Abweichung (`rel_delta`) verwendet; nur Features mit ausreichender Häufigkeit werden berücksichtigt. Daraus werden Regeln erzeugt: `gt` bei deutlich höheren, `lt` bei deutlich niedrigeren Mittelwerten sowie optional `between` bei Zwischenlagen. Die Schwellen liegen bei `gt`: $\mu_s - 0.5\sigma_s$, `lt`: $\mu_s + 0.5\sigma_s$ und `between`: $[\mu_s - 2\sigma_s, \mu_s + 2\sigma_s]$. Die Gewichte sind fest codiert (1,5 für `gt`, 1,0 für `lt`, 0,5 für `zwischen`).

Ich wähle diese Werte als lineare Staffelung. Eine Verifikation oder weitere Erprobung optimaler Gewichte kann hier noch Optimierungspotenzial bieten.

4.1.2 Vergleich von HMM und CRF im Update-Schritt

Beide Modelle erhalten denselben Likelihood-Vektor aus den Regeln. Im HMM stammen die Übergänge aus der Übergangsmatrix A , die per MLE mit Glättung geschätzt wird. Das Update erfolgt als

$$b_t \propto (b_{t-1}A) \odot \text{likelihood},$$

optional mit Diffusion über den Wert der Änderung aus einem Kalman-filter. Das CRF nutzt dieselben Emissionswahrscheinlichkeiten, führt jedoch ein diskriminatives Sequenz-Update aus. Optional wird nur die Übergangsmatrix online nachtrainiert, während die Regeln fix bleiben.

4.2 BEGRÜNDUNG DER ENTSCHEIDUNGEN INNERHALB DES METHODIKTEILS

Bei der Auswahl der Modelle spielte vor allem die rechnerische Effizienz eine Rolle. Aus diesem Grund wurden die benötigten Features auf einen kleinen, festen Vektor reduziert und Zustände bevorzugt, die über Farbraum- und Texturinformationen unterscheidbar sind. Da organische Strukturen im Video unterschiedliche Farb- und Texturmuster sowie einen unterschiedlichen zeitlichen Kontext besitzen, wird die Klassifikation durch einen sequenziellen Kontext ergänzt. Dazu werden aus einem Trainingsdatensatz statische Featureregeln abgeleitet, die für bestimmte Zustände signifikant häufig auftreten, und als feste Emissionsregeln verwendet. Die Übergangsmatrix wird aus annotierten Sequenzen per MLE mit Glättung geschätzt; die Regeln selbst bleiben während der Inferenz fixiert. Im CRF erfolgt optional eine Online-Aktualisierung der Übergangsgewichte, nicht der Regeln. Der Zustandsraum wird reduziert, indem schwer differenzierbare Klassen zusammengefasst werden. Innerhalb des HMM wird der Kalman-Change-Detector auf dem 6-D-Merkmalvektor eingesetzt, um eine Änderungswahrscheinlichkeit zu berechnen; diese steuert eine Diffusion der Prior, sodass schnelle Wechsel stärker Zustandswechsel begünstigen.

5.1 SYSTEMARCHITEKTUR UND ÜBERBLICK

Dieses Kapitel überführt die theoretischen Modelle in eine konkrete Systemarchitektur. Es wird hier auf einen hybriden Entwurf gesetzt: Klassische Computer Vision trifft auf probabilistische Zeitreihenanalyse und Deep Learning.

Das primäre Ziel ist es, die bei reinen Frame-zu-Frame CNN-Ansätzen häufig auftretende Instabilität zu eliminieren. Dies wird erreicht, indem physikalische Kontinuität via optischem Fluss und zeitliche Kohärenz via HMM/CRF als starke Priors in den Entscheidungsprozess integriert werden.

Der Code der für die Modelle sowie das Training und die Evaluation genutzt wurde ist öffentlich auf: [[empty citation](#)]maxhildDevisions

5.1.1 *Von heuristischen Regeln und Expertensystemen zur probabilistischen Inferenz*

Historisch basieren viele Ansätze in der Endoskopie-Analyse auf regelbasierten Expertensystemen mit harten Schwellenwerten. In der klinischen Realität erweisen sich starre Grenzen jedoch oft als unzureichend, da die Variabilität von Gewebetextur, Beleuchtung, Gerätetypen und Pathologie zu groß ist. Außerdem ist es Menschen möglich, fokussiert einzelne Bereiche und Muster des Videos zu erkennen, ein Umstand der schwierig über Differenzen von Unterschieden und Bewegungsvektoren generalisierbar ist.

Die Lösung kombiniert regelbasierte Beobachtungsmodelle mit probabilistischer Sequenzmodellierung indem die Merkmale vorher statistisch erhoben werden. Durch diese Initialisierung der Features aufgrund tatsächlicher Messungen vor der Durchführung initialisiert das System die Parameter bei realistischen Werten. Die Übergangsmatrizen werden aus annotierten Sequenzen per MLE mit Glättung geschätzt, vorher definierten Feature-Statistiken fixiert in die Inferenz eingebracht werden.




Abbildung 5.1: Systemarchitektur der Featurekalibrierung und des Trainings und CRF sowie der Anlegung von Messvektorprototypen innerhalb des HMM (Der Messvektor wird nicht aktiv in der Inferenz genutzt, diese Komponente existiert für eine spätere Weiterentwicklung.)

5.2 DEFINITION DES HMMS

5.3 MERKMALEXTRAKTION UND REDUKTION DES BEOBACHTUNGSRAUMS

Um die Echtzeitanforderungen einer klinischen Assistenzsoftware zu erfüllen, wird auf die direkte Verwendung rechenintensiver Deep Learning Features innerhalb der probabilistischen Filter verzichtet. Stattdessen wird jedes Videobild I_t zu einem Zeitpunkt t auf einen kompakten, niederdimensionalen Messvektor $y_t \in \mathbb{R}^6$ projiziert. Dieser Vektor aggregiert globale Informationen über Bewegung, Farbverteilung und Bildstruktur.

Der Messvektor y_t ist definiert als:

$$y_t = [v_{x,t} \quad v_{y,t} \quad \mu_{H,t} \quad \mu_{S,t} \quad \mu_{V,t} \quad E_{\text{text},t}]^T \quad (5.1)$$

Im Folgenden wird die Herleitung der Farb- und Bewegungskomponenten detailliert beschrieben. Der Messvektor y_t wird nicht direkt zur Berechnung der Emissionswahrscheinlichkeiten verwendet, sondern ausschließlich für Änderungserkennung durch die gelernten Featureregeln und optionale Prototypisierung eingesetzt.

5.3.0.1 Statistische Modellierung

Ein zentrales Problem bei der automatisierten Analyse endoskopischer Videos ist das signifikante Sensorrauschen, das durch die geringe Baugröße der Bildsensoren und die schwierigen Lichtverhältnisse im Körperinneren entsteht. Theoretische Arbeiten, wie die von Hwang et al., weisen darauf hin, dass dieses Rauschen oft nicht einer idealen Normalverteilung folgt, sondern breite Ränder aufweist. Während Ansätze zur reinen Bewegungserkennung dieses Rauschen explizit durch komplexe Verteilungsmodelle (z. B. Generalized Exponential Models) abbilden müssen, um Fehlalarme bei der Differenzbildung (Δ) zu vermeiden, verfolgt die vorliegende Arbeit einen diskriminativen, zustandsbasierten Ansatz. [hwang2008generalized]

Anstatt die Wahrscheinlichkeit des Rauschens in der zeitlichen Ableitung zu modellieren, wird der Zustand s_t über absolute Featureregeln in einem mehrdimensionalen Merkmalsraum $\mathbb{R}^n$ definiert. Die Robustheit gegenüber nicht-gaußischem Rauschen entsteht durch die Kombination orthogonaler Merkmale (Farbe, Helligkeit, Textur), die als deterministische Regeln in die Emissionsberechnung eingehen.

Die Regeln werden vor dem Onlinetraining aus den nach Labels stratifizierten Daten statistisch abgeleitet. Für jedes Feature werden Mittelwert und Standardabweichung je Label sowie global bestimmt (Welford-Algorithmus). Weicht der Klassenmittelwert signifikant vom globalen Mittel ab, wird eine One-Sided-Regel gesetzt (Schwellwert $\mu_s \pm 0.5\sigma_s$). Optional werden Between-Intervalle ($\mu_s \pm 2\sigma_s$) erzeugt.

5.3.0.2 Abgeleitete Heuristiken

Auf Basis der statistischen Modellierung werden konkrete Regeln für die Emissionsberechnung abgeleitet. Dazu zählen Farbregele wie `rule_outside_color` und `rule_nbi_color` sowie Texturregele wie `rule_low_quality_soft` und `rule_blur_suspected`. Für LBP-Texturmerkmale werden beispielsweise Heuristiken der Form

$$\phi_{\text{outside}}(I_t) = \mathbb{I}(h_{t,8} \geq \tau_{\text{outside}}), \quad (5.2)$$

verwendet. Zusätzlich wird die Distanz zwischen aufeinanderfolgenden LBP-Histogrammen betrachtet,

$$d_t = \|h_t - h_{t-1}\|_2, \quad (5.3)$$

aus der stabile bzw. schockartige Übergänge (`temp_texture_stable`, `temp_texture_shock`) abgeleitet werden.

5.3.1 Globale Bewegungsschätzung

Die relative Bewegung der Kamera korreliert stark mit den prozeduralen Phasen. Zur Schätzung wird zunächst das dichte optische Flussfeld F_t berechnet. Da endoskopische Aufnahmen oft lokale Störungen enthalten (z. B. bewegte Instrumente, Flüssigkeiten), ist der arithmetische Mittelwert des Flussfeldes kein robuster Schätzer für die globale Kamerabewegung. Stattdessen wird der *Median* der Flusskomponenten verwendet, um Ausreißer effektiv zu unterdrücken:

$$v_{x,t} = \text{median}_{(u,v)}\{\delta x \mid (\delta x, \delta y) \in F_t\} \quad (5.4)$$

$$v_{y,t} = \text{median}_{(u,v)}\{\delta y \mid (\delta x, \delta y) \in F_t\} \quad (5.5)$$

5.4 ZUSTANDSOPTIMIERUNG MITTELS LIKELIHOOD-VEKTOR

Die Entscheidung über den aktuellen Systemzustand S_t basiert auf einem Likelihood-Vektor, der aus den regelbasierten Beobachtungsmerkmalen pro Frame berechnet wird. Die Regeln liefern deterministische Scores je Zustand, die zu einem Likelihood-Vektor $P(y_t \mid S_t)$ zusammengefasst werden. Der HMM-Schritt kombiniert diese Emissionen mit der Übergangsmatrix:

$$P(S_t) \propto A^T P(S_{t-1}) \odot P(y_t \mid S_t) \quad (5.6)$$

Damit bildet der Likelihood-Vektor die Brücke zwischen den heuristischen Regeln und der probabilistischen Zustandsaktualisierung. Optional wird ein Unsicherheitsfaktor aus dem Kalmanfilter verwendet, um eine Diffusionskomponente (zusätzliche Unsicherheit) in die zeitliche Aktualisierung einzubringen. Die finale Zustandsentscheidung erfolgt über das Maximum der posterioren Verteilung.

5.5 DEFINITION DES CRF

Während das HMM einen generativen Ansatz verfolgt ($P(X, O)$), wird in dieser Arbeit ergänzend ein diskriminativer Ansatz untersucht. Ein Conditional Random Field modelliert direkt die bedingte Wahrscheinlichkeit $P(X | O)$ der Zustandssequenz. Dies ist besonders vorteilhaft für die Unterscheidung von Zuständen mit ähnlichen physikalischen Eigenschaften, die sich jedoch im Kontext unterscheiden (z. B. fließendes Blut vs. bewegtes Instrument).

Ein Linear Chain CRF definiert die Wahrscheinlichkeit als:

$$P(X | O) = \frac{1}{Z(O)} \exp \left(\sum_{t=1}^T \sum_k \lambda_k f_k(s_{t-1}, s_t, O, t) \right), \quad (5.7)$$

wobei die Feature-Funktionen f_k konzeptionell die Abhängigkeiten zwischen Zuständen und Beobachtungen beschreiben. In der implementierten Pipeline werden die Beobachtungen als Emissionswahrscheinlichkeiten aus den hergeleiteten Regeln berechnet und dem CRF als Eingabe übergeben. Optional wird bei verfügbaren Labels eine Online-Aktualisierung der Übergangsgewichte durchgeführt; die Regeln selbst bleiben fixiert. Vgl.: [10.5555/645530.655813]

5.6 TEXTURANALYSE MIT LOCAL BINARY PATTERNS

Zur Analyse der lokalen Bildtextur wird in dieser Arbeit das Verfahren der *Local Binary Patterns* (LBP) verwendet. Konkret kommt die rotationsinvariante, uniforme Variante ($LBP_{P,R}^{riu2}$) zum Einsatz, wie sie von Ojala et al. [Ojala2002] definiert wurde. Die Implementierung erfolgt unter Verwendung der *scikit-image* Bibliothek.

5.6.1 Algorithmus und Rotationsinvarianz

Der LBP-Operator betrachtet für jeden Pixel eine kreisförmige Nachbarschaft mit Radius R und P Nachbarn. Um Rotationsinvarianz zu erreichen, wird das binäre Muster bitweise rotiert, bis es den minimalen dezimalen Wert erreicht. Zusätzlich werden nur uniforme Muster als eigenständige Merkmale betrachtet. Ein Muster gilt als uniform, wenn es maximal zwei bitweise Übergänge ($0 \rightarrow 1$ oder $1 \rightarrow 0$) enthält. [scikit-image]

Dies führt zu einer drastischen Reduktion des Merkmalsraums. Die Anzahl der resultierenden Bins (Merkmalsdimensionen) berechnet sich gemäß der verwendeten Implementierung als:

$$K = P + 2 \quad (5.8)$$

Bei der gewählten Parametrisierung von $P = 8$ Nachbarn und Radius $R = 1$ entstehen somit $K = 10$ Bins.

5.6.2 Interpretation der Histogramm-Bins

Das extrahierte Histogramm $H = (h_0, \dots, h_9)$ beschreibt die statistische Verteilung dieser rotationsinvarianten Muster im Bildframe:

- **Bins 0 bis 8 (Uniform Patterns):** Diese Bins korrespondieren direkt mit der Anzahl der "1"en in der binären Nachbarschaft.
 - Niedrige Indizes (z. B. Bin 0) stehen für dunkle Flecken.
 - Hohe Indizes (z. B. Bin 8) stehen für helle Flecken.
 - Mittlere Indizes repräsentieren Kanten unterschiedlicher Stärke.
- **Bin 9:** Dieser Sammel-Bin enthält alle Muster, die mehr als zwei Bit-Übergänge aufweisen. Ein hoher Wert in diesem Bin deutet oft auf unstrukturiertes Rauschen oder hochfrequente, komplexe Texturen hin, die keiner klaren Geometrie folgen.

5.6.3 Abgeleitete Metriken

Zusätzlich zu den einzelnen Bins wird ein Komplexitätsmaß abgeleitet. Dieses berechnet sich als die Summe der Häufigkeiten der letzten drei Bins:

$$C_{LBP} = \sum_{i=K-3}^{K-1} h_i \quad (5.9)$$

Dies aggregiert Bereiche mit hoher lokaler Helligkeit und nicht-uniformen Strukturen (Rauschen), was als Indikator für visuelle Unruhe im Frame dienen kann.

5.7 ZUSAMMENSETZUNG UND LIMITATIONEN DES DATENSETS

Die Setzung der Grenzwerte für die Featureregeln wurde auf einem durch einen Arzt frameweise annotiertem Datenset durchgeführt. Dieses ist vollständig annotiert, setzt mehrere Labels pro Frame und enthält die folgenden Daten:

Die Boxplots der wichtigsten Merkmale zur Kalibrierung sind in Abbildung 5.3 dargestellt.

5.8 REDUKTION DES LABELRAUMS

Für die Modellierung wurde der ursprüngliche Labelraum auf eine kleinere Menge semantischer Klassen reduziert. Ziel ist eine robuste Trennung der für die Nachbearbeitung relevanten Zustände bei gleichzeitiger Reduktion der Varianz innerhalb der Klassen. Die Boxplots der Farb- und Texturmerkmale zeigen, dass sich die Gruppen *outside*, *blood*, *polyp* sowie die Sammelklassen *instrument* und *low_quality* in den verwendeten Merkmalen (Hue, Sättigung, LBP Komplexität) hinreichend




Abbildung 5.2: Zugrundeliegendes wahres Markovmodell für die Endoskopie bei normaler Anatomie

Tabelle 5.1: Kalibrierung der Features: Dataset Multilabel Classification

Label	Anzahl Frames im Dataset zur Kalibrierung
anal_channel	7
appendix	1157
blood	1137
bubbles	1007
cleaning	690
clip	71
diverticule	139
endoscope_reflection	29
endoscope_retroflexion	10
grasper	1079
ileocecavalve	1150
ileum	1037
low_quality	1762
nbi	440
needle	62
outside	1380
petechia	355
polyp	1532
snare	1762
stool	1601
water_jet	877
wound	426
Insgesamt (Nicht alle Frames wurden annotiert, manche doppelt.)	14502




Abbildung 5.3: Boxplots der zentralen Kalibrierungsmerkmale (Hue, Sättigung und LBP-Komplexität) aus dem Datenset.

differenzieren lassen, während die anderen Features nicht ausreichend abweichen. Deshalb wurde eine Reduzierung des Featureraum möglich. Dadurch wird eine stabile Entscheidungslogik mit wenigen, gut separierbaren Klassen möglich.

Die Abbildung der Labels erfolgte nach den folgenden Regeln:

Tabelle 5.2: Abbildung der ursprünglichen Labels auf reduzierte Klassen.

Reduzierte Klasse	Zugeordnete Labels
nbi	nbi, narrow_band_imaging
outside	outside
blood	blood
polyp	polyp
instrument	instrument, grasper, gripper, snare, needle, clip, endocuff, water_jet
low_quality	low_quality, stool, bubbles, cleaning, endoscope_reflection, endoscope_retroflexion
mucosa	alle übrigen Labels

Die Anzahl der annotierten Frames pro reduzierter Klasse ist in Tabelle 5.3 zusammengefasst.

Tabelle 5.3: Annotierte Frames pro reduzierter Klasse (Datensatz für den Modellvergleich).

Reduzierte Klasse	Anzahl Frames
blood	20163
low_quality	19973
nbi	412
outside	3604
polyp	15133
Insgesamt	181716

Im Rahmen der Inferenz wurde auf drei weitere Endoskopievideos zurückgegriffen, die im Rahmen einer klinischen Registerstudie aufgenommen wurden. Zur Annotation wurde innerhalb der Bearbeitungszeit für diese Masterarbeit für die Forschungsgruppe eine App fertiggestellt, welche die Reduktion persönlicher Daten sowie die segmentweise Frameannotation auf den Endoskopievideos ermöglicht. Sie ist einsehbar auf [[empty citation](#)]. Für die Anonymisierung wurden Algorithmen der Forschungsgruppe basieren. Vgl: [[Lux2025EndoRegDB](#)][[Lux2025LocalLLMAnonymization](#)] Das bedeutet, dass die für die Evaluation der Modelle verwendeten Frameannotationen aus Segmenten stammen. Segmente sind hier mit Zeitstempeln versehene Abschnitte des Videos. Basierend auf den FPS wurden die zugehörigen Framenummern bestimmt. Diese konnten dann mit den zugehörigen Labels bei der Analyse verwendet werden. Aufgrund der verwendeten FPS von $50 \frac{\text{Frames}}{\text{Sekunde}}$ entsteht die Problematik, dass bei der Berechnung der Start und Endzeit:

$$\text{Framenummer } F = \text{Zeit in Sekunden} \cdot \text{FPS} \quad (5.10)$$

Eine Rundung auf 50 Frames notwendig ist. Dadurch sowie durch zu spätes oder zu frühes Setzen der Start- und Endzeiten entstehen bei dieser Methode unvermeidbare Ungenauigkeiten.

Das Datenset zur Evaluation und Inferenz enthielt nicht alle Frames, da das Label Mucosa nicht annotiert wurde.

Das Online-Training des CRF, das Prototyping des HMM sowie die Inferenz wurden auf diesem Datensatz durchgeführt. Durch die Analyse der labelbasierten Streuung der Werte der Features in Boxplot und mittels LLM wurden einige der Labels zusammengefasst. Im ersten Durchlauf wurde jedes Video einzeln durchlaufen. Hierbei wurde das Onlinetraining für das CRF während einer Durchführung aktiviert um die Labels für den Datensatz anzupassen.

ERGEBNISSE

6.1 VERGLEICH DER ERGEBNISSE DES HMM SOWIE DES CRF

6.2 ANALYSE DER ERGEBNISSE DES VERGLEICHS VON HMM UND CRF

Die Modelle wurden zuerst

Die Eingangs beschriebenen Modelle unterscheiden sich vor allem in einem Punkt: Während das HMM mit Kalman-Diffusion ohne Training die wahrscheinlichste Abfolge aus den Features schätzt, nutzt das CRF gelernte Gewichte für die existierenden Featurefunktionen. Aus diesem Grund ist die Erwartung, dass sich die Performance des CRF mit dem Training verbessert.

6.3 DISKUSSION DER ERGEBNISSE UND IMPLIKATIONEN FÜR DIE SYSTEMARCHITEKTUR

Die quantitative Auswertung der HMM- und CRF-Modelle offenbart eine signifikante Dichotomie in der Klassifikationsleistung, die für das Design einer effizienten Analyse-Pipeline von entscheidender Bedeutung ist. Während die Modelle bei der Differenzierung pathologischer Befunde (insbesondere *polyp* vs. *blood*) deutliche Schwächen zeigen – was sich in einer Polyp-Erkennungsrate von unter 25 % selbst im besten CRF-Szenario widerspiegelt, demonstrieren sie Robustheit bei der Identifikation irrelevanter Videosequenzen.

Insbesondere die Klassen *outside* - Frames außerhalb des Videos wurden mit einer Genauigkeit von bis zu 98 % korrekt klassifiziert. Frames mit dem label *low_quality* - Frames mit schlechter Bildqualität - wurden Die Analyse der Konfusionsmatrizen legt nahe, dass die verwendete

Tabelle 6.1: Genauigkeit der beiden Modelle über beide Durchläufe. Durchlauf 2 Zeigt den Effekt des Trainings des CRF.

Modell	blood	low_quality	nbi	outside	polyp	Insgesamt
HMM - Durchlauf 1	0,0	0,489	0,010	0,977	0,0067	0,331
HMM - Durchlauf 2	0	0,480	0,008	0,974	0,0067	0,328
CRF - Durchlauf 1	0,270	0,491	0,217	0,966	0,156	0,427
CRF - Durchlauf 2	0,439	0,708	0,012	0,960	0,156	0,511

Tabelle 6.2: Laufzeitanalyse (inkl. Feature-Extraktion und Diffusion) auf 500 Frames.

Bereich	Kennzahl	HMM	CRF
Gesamt			
Frames verarbeitet	Anzahl	500	500
Laufzeit	Wall-clock	23,18 s	23,18 s
Durchsatz	FPS	21,6	21,6
Feature-Extraktion (ms)			
Mittelwert	mean	34,50	34,50
Median	median	31,09	31,09
Perzentil	p90	44,08	44,08
Minimum	min	29,47	29,47
Maximum	max	180,99	180,99
Inferenzzeiten (ms)			
Mittelwert	mean	0,03	0,16
Median	median	0,03	0,14
Perzentil	p90	0,04	0,22
Minimum	min	0,03	0,12
Maximum	max	0,11	1,03
Gesamt pro Frame (ms)			
Mittelwert	mean	34,53	34,69
Median	median	31,13	31,28
Perzentil	p90	44,11	44,25
Minimum	min	29,50	29,64
Maximum	max	181,03	181,20

Tabelle 6.3: Präzision, Recall und F1 über alle Videos.

Modell	Label	Precision	Recall	F1	Support
HMM	blood	0,00%	0,00%	0,00%	27902
CRF	blood	30,49%	43,91%	35,99%	27902
HMM	low_quality	81,42%	48,02%	60,41%	57733
CRF	low_quality	65,98%	70,81%	68,31%	57733
HMM	nbi	1,76%	0,86%	1,15%	9435
CRF	nbi	12,47%	1,16%	2,11%	9435
HMM	outside	44,38%	97,42%	60,98%	32312
CRF	outside	59,98%	96,04%	73,84%	32312
HMM	polyp	48,47%	0,67%	1,33%	54333
CRF	polyp	50,29%	15,63%	23,85%	54333
Macro F1		0,138	–	0,227	–
Micro F1		0,328	–	0,511	–

ten farbbasierten Merkmale ausreichen, um technische Artefakte und extrakorporale Aufnahmen zuverlässig von organischem Gewebe zu trennen.

INTERPRETATION DER F1-SCORES. Da das vorliegende Datenset eine starke Klassenimbalance aufweist, ist die alleinige Betrachtung der Genauigkeit nur eingeschränkt aussagekräftig. Der F1-Score, als harmonisches Mittel aus Precision und Recall, erlaubt eine robustere Bewertung der Klassifikationsleistung, da er sowohl Fehlklassifikationen als auch verpasste Erkennungen berücksichtigt.

Für das HMM zeigt sich, dass mehrere Klassen – insbesondere *blood* und *polyp* – praktisch nicht erkannt werden (F1 nahe 0), obwohl die Gesamtgenauigkeit durch dominante Klassen wie *outside* relativ hoch ausfällt. Dies spiegelt die Limitierung eines rein regelbasierten, generativen Modells wider, dessen Übergangsdynamik seltene Zustände unterdrücken kann.

Das CRF erreicht durch das Training der Übergangsgewichte signifikant höhere F1-Werte in nahezu allen Klassen. Besonders für *outside* (F1 = 73,84%) und *low_quality* (F1 = 68,31%) wird eine robuste Balance zwischen Precision und Recall erzielt. Für pathologische Klassen wie *polyp* und *blood* verbessert sich der F1-Score deutlich gegenüber dem HMM, verbleibt jedoch unterhalb eines für eine alleinige diagnostische Nutzung ausreichenden Niveaus.

Der Vergleich von Macro- und Micro-F1 verdeutlicht diese Beobachtung: Während der Micro-F1 des CRF (0,511) einen substantiellen Gesamtgewinn belegt, bleibt der Macro-F1 (0,227) begrenzt. Dies zeigt,




Abbildung 6.1: Vergleich der Modellleistung über alle Videos.

dass das Modell insbesondere für häufige und klar separierbare Klassen zuverlässig arbeitet, während seltene oder visuell komplexe Zustände weiterhin eine Herausforderung darstellen.

Diese Beobachtung motiviert den Einsatz eines kaskadierten Systemansatzes, welches das Filtern der Frames mit dem CRF mit dem Einsatz anderer Modelle zu kombinieren. Die stochastischen Modelle qualifizieren sich aufgrund ihrer geringen Inferenzzeit (ca. 30 ms pro Frame) ideal als Vorfilterstufe. In einer kombinierten Pipeline übernimmt das CRF-Modell die Rolle eines *Gatekeepers*, der den Datenstrom effizient um nicht-diagnostische Frames bereinigt. Der verbleibende, signifikant reduzierte Datenbestand kann anschließend an ein leistungsstärkeres, aber rechenintensiveres Convolutional Neural Network (CNN) oder an ein Vision Transformer Modell übergeben werden. Durch diese Arbeitsteilung lässt sich die Effizienz des Systems steigern, indem die Ressourcen des CNNs gezielt auf die schwierigen pathologischen Unterscheidungen fokussiert werden, während das CRF die Echtzeitfähigkeit des Systems durch schnelle Vorselektion gewährleistet.

DISKUSSION

Innerhalb dieser Arbeit wurde gezeigt, dass der Einsatz markovbasierter Modelle grundsätzlich möglich ist. Vorteile bieten hier die schnelle Laufzeit, die Erweiterbarkeit sowie die schnelle Anpassungsfähigkeit an neue Daten. Die Datenerhebung innerhalb der ColoReg Studie, die Grundlage für die Erhebung der hier vorgestellten Ergebnisse bildete, erfolgte unter klinischen Bedingungen. Daher sind die erhobenen Daten naturgemäß mit Störeinflüssen behaftet, die in einem realen klinischen Umfeld auftreten können. Diese Störeinflüsse haben sich auf die Qualität der erfassten Daten ausgewirkt und somit die Aussagekraft der Ergebnisse eingeschränkt. Beispielsweise traten bei einigen Patienten Bewegungsartefakte auf, die die Genauigkeit der Messungen beeinträchtigten. Zudem gab es Fälle von unvollständigen Datensätzen aufgrund technischer Probleme während der Datenerfassung. Diese Faktoren führten dazu, dass bei der Evaluierung die vollständige Datenbasis nicht genutzt werden konnte, was die statistische Signifikanz der Ergebnisse reduzierte. Trotz dieser Einschränkungen konnten jedoch wertvolle Erkenntnisse gewonnen werden, die als Grundlage für zukünftige Studien dienen können. Zukünftige Untersuchungen sollten darauf abzielen, die Datenerhebung unter kontrollierteren Bedingungen durchzuführen, um die Qualität der Daten zu verbessern und die Aussagekraft der Ergebnisse zu erhöhen.

Im Hinblick auf die Ergebnisse zeigt der Vergleich über alle Videos, dass das CRF in der Summe konsistenter als das HMM arbeitet. Das spiegelt sich insbesondere in der höheren Micro-F1 und Macro-F1 wider, was auf eine robustere Gesamtleistung bei unterschiedlichen Klassen hinweist. Gleichzeitig bleibt die Polypenerkennung auch im CRF deutlich hinter den Anforderungen zurück, da die Recall-Werte niedrig sind und damit viele relevante Ereignisse unentdeckt bleiben. Dies unterstreicht die Grenze der rein regelbasierten Merkmalsbildung für Befunde, die nicht ausreichend von den gewählten Features abgebildet werden.

Demgegenüber ist die Klasse Außerhalb mit sehr hoher Trefferquote erkennbar, was den Einsatz der Modelle als Vorfilter stützt. Diese Leistung ist für die angestrebte Anonymisierung und die automatische Segmentierung relevant, da hier verlässliche Entscheidungen getroffen werden können. Die Laufzeitanalyse zeigt zudem, dass beide Verfahren im Millisekundenbereich pro Frame arbeiten und damit als Echtzeitkomponenten geeignet sind.

Zusammenfassend lässt sich festhalten, dass die Modelle für die robuste Trennung irrelevanter Videosegmente geeignet sind, während die

präzise Erkennung pathologischer Befunde weiterhin auf stärkere visuelle Modelle angewiesen bleibt. Eine vielversprechende Perspektive ist daher die Kombination mit lernbasierten Verfahren, die die Erkennung von texturellen Features verbessern, während die Markovmodelle die zeitliche Stabilität und Vorselektion gewährleisten.

7.0.1 *Ausblick auf Weltmodelle*

Um zu zeigen, dass ein in der realen Welt existierendes System durch ein prädiktives Modell hinreichend abgedeckt wird, kann es oft sinnvoll sein, ein simulierendes Modell des Systems zu erstellen. Innerhalb dieses Systems sollten die mit Sensoren messbaren Eigenschaften in interne Zustände und daraus ableitbar in Aktionen oder Vorhersagen überführt werden können.

Jürgen Schmidhuber schlug 1990 vor, die Welt, innerhalb derer ein neuronales Netzwerk operiert, durch zwei interagierende Netzwerke zu modellieren: ein Modellnetzwerk, das die Dynamik der Umgebung simuliert und vorhersagt, und ein Controllernetzwerk, das Aktionen ausführt. Die zentrale Idee war, die Umgebung durch das Modellnetzwerk differenzierbar zu machen, sodass der Fehler der Vorhersage genutzt werden kann, um das System mittels Gradientenabstieg zu optimieren. [schmidhuber1990making] Diese Idee wird aufgrund der Problematik eines Gedächtnisses bei der Nutzung großer Sprachmodelle oder Bildverarbeitungsmodelle wieder aktuell. Das Problem der Vorverarbeitung einer Segmentierung von Endoskopievideos zu Dokumentationszwecken kann als ein solches System betrachtet werden. Hierbei sind die Bilder des Videos die messbaren, hochdimensionalen Eigenschaften des Systems. Diese müssen in kompakte Zustände überführt werden, die den aktuellen Status des Endoskops im Darm abbilden. Daraus können für durch die Messungen adäquat abbildbare Zustände wie den Zustand Außerhalb Wahrscheinlichkeiten abgeleitet werden, wie sich das Endoskop im nächsten Zeitschritt verhalten wird oder welcher Abschnitt des Eingriffs als nächstes sichtbar wird. Eine Aktion lässt sich im endoskopischen Kontext als implizite Kamerabewegung interpretieren, etwa als Rückzug oder Vorschub des Endoskops, die den Übergang zwischen anatomischen Zuständen steuert. Modernere Ansätze, wie die von [ha2018worldmodels] vorgestellten Weltmodelle, adressieren die Schwierigkeit, hochdimensionale visuelle Daten wie Videobilder zu modellieren. Eine Weiterentwicklung des Weltmodellkonzepts stellt die Dreamerarchitektur von Hafner et al. hafner2019dreamer dar. Anstatt zukünftige Pixel aus den beobachteten Pixeln vorherzusagen, was rechenintensiv und fehleranfällig ist, lernen diese Modelle die Dynamik ausschließlich im latenten Raum.

Eine Frage, die zum Abschluss der Arbeit aufkam, ist ob sich Markovmodelle hier als Komponente für die Entwicklung von World Models eignen. Die Zielsetzung, das Video bereits vor der Verarbeitung zu

segmentieren, passt konzeptuell in die Idee eines World Models, und die Eigenschaften von Markovmodellen könnten hier in hybriden Systemen nützen, um zeitlichem Kontext Stabilität zu verleihen und Teile der Modellierung effizient probabilistisch zu modellieren. Ein Modell, das gelernt hat, wie die Anatomie und der Ablauf der Endoskopie wahrscheinlich aussieht, ist robuster gegenüber Rauschen (z. B. Unschärfe, Spiegelungen oder Verschmutzungen der Linse), da es nicht versucht, jedes Pixel exakt zu rekonstruieren, sondern den semantischen Inhalt der Szene über die Zeit zu verfolgen. Das Endoskopieszenario lässt sich abschließend als partiell beobachtbarer Markovprozess beschreiben. Der Arzt sieht nie den gesamten Darm, sondern nur einen Ausschnitt. Aus dieser Annahme heraus sollte es durch die Nutzung des zeitlichen Kontext auch einem Algorithmus möglich sein zu lernen, in welcher Phase des Eingriffs er sich wahrscheinlich befindet.

Teil I

ANHANG



BOXPLOTS DER MERKMALE

Dieser Anhang dokumentiert alle Boxplots der Merkmalsverteilungen, die im Rahmen der Kalibrierung des regelbasierten Systems erzeugt wurden.




Abbildung A.1: Boxplot der Hue-Verteilung.




Abbildung A.2: Boxplot der Sättigungs-Verteilung.




Abbildung A.3: Boxplot der Value-Verteilung.




Abbildung A.4: Boxplot der LAB-L-Verteilung.




Abbildung A.5: Boxplot der LAB-a-Verteilung.




Abbildung A.6: Boxplot der LAB-b-Verteilung.




Abbildung A.7: Boxplot der LBP-Komplexität.




Abbildung A.8: Boxplot des LBP-Bins 0.




Abbildung A.9: Boxplot des LBP-Bins 1.




Abbildung A.10: Boxplot des LBP-Bins 2.




Abbildung A.11: Boxplot des LBP-Bins 3.




Abbildung A.12: Boxplot des LBP-Bins 4.




Abbildung A.13: Boxplot des LBP-Bins 5.




Abbildung A.14: Boxplot des LBP-Bins 6.




Abbildung A.15: Boxplot des LBP-Bins 7.




Abbildung A.16: Boxplot des LBP-Bins 8.




Abbildung A.17: Boxplot des LBP-Bins 9.

CNN	Convolutional Neural Network
CRF	Conditional Random Field
HMM	Hidden Markov Model
ViT	Vision Transformer
X	Zustandssequenz
O	Beobachtungssequenz
S	Zustandsraum
s_i	i-ter Zustand
o_t	Beobachtung zum Zeitpunkt t
y_t	Messvektor zum Zeitpunkt t
t	Zeitindex
Z_1	Zeitpunkt des Erreichens des terminalen Ileums
Z_2	Zeitpunkt des Austritts aus dem Körper
$\delta(Z_1, Z_2)$	Zökumrückzugszeit
Q	Query-Matrix im Attention-Mechanismus
K	Key-Matrix im Attention-Mechanismus
V	Value-Matrix im Attention-Mechanismus
d	Skalierungsfaktor der Attention-Berechnung

ERKLÄRUNG

Ich versichere, dass ich die vorliegende Arbeit selbstständig und nur unter Verwendung der angegebenen Quellen und Hilfsmittel angefertigt habe, insbesondere sind wörtliche oder sinngemäße Zitate als solche gekennzeichnet. Mir ist bekannt, dass Zuwiderhandlung auch nachträglich zur Aberkennung des Abschlusses führen kann. Ich versichere, dass das elektronische Exemplar mit den gedruckten Exemplaren übereinstimmt.

Ich erkläre, dass ich im Rahmen der Erstellung dieser Arbeit KI-basierte Dienste eingesetzt habe, um z.B. Texte zu korrigieren, zusammenzufassen oder umzuformulieren. Ich versichere, dass ich die betreffenden Textstellen manuell geprüft habe und für diese die volle Verantwortung als Autor/Autorin übernehme. Konkret habe ich folgende Dienste zu folgenden Zwecken genutzt:

Dienst	Verwendungszweck
Gemini 3 Pro	Programmialgorithmus, Literaturrecherche und LaTeX-Formatierungshilfe.
Chat GPT 5.2 Codex DeepL Translate	Programmialgorithmus, Formatierung. Übersetzen der russischen Originalquellen ins Deutsche.

Leipzig, 03. Februar 2026



Max Hild